

SVEUČILIŠTE JOSIPA JURJA STROSSMAYERA U OSIJEKU
FAKULTET ELEKTROTEHNIKE, RAČUNARSTVA I
INFORMACIJSKIH TEHNOLOGIJA OSIJEK

Sveučilišni diplomski studij Računarstvo

SEMANTIČKA SEGMENTACIJA GRANA STABALA IZ
RGB-D SLIKA PRIMJENOM DUBOKOG UČENJA

Diplomski rad

Samuel Adžić

Osijek, 2026.

Sadržaj

1.	UVOD	1
2.	PREGLED PODRUČJA SEGMENTACIJE GRANA STABALA NA RGB-D SLIKAMA.	3
2.1.	Percepcija scene u robotiziranom voćarstvu	3
2.2.	RGB-D podaci i njihova fuzija	3
2.3.	Arhitekture za RGB-D semantičku segmentaciju	5
2.4.	Segmentacija dijelova stabla	6
2.5.	Odabir arhitekture i motivacija	7
2.6.	Sinteza pregleda.	7
3.	METODOLOGIJA	9
3.1.	Teorijska pozadina	9
3.2.	Definicija problema	10
3.3.	Strategije integracije modaliteta dubine.	11
3.3.1.	Rana fuzija s jednokanalnom dubinom	11
3.3.2.	HHA enkodiranje dubine	12
3.3.3.	Paralelne enkoder grane (ESANet pristup)	12
3.3.4.	Prethodno treniranje na RGB-D podacima (DFormer pristup)	13
3.4.	Odabrane arhitekture	13
3.4.1.	Prva eksperimentalna grupa	14
3.4.2.	Druga eksperimentalna grupa	14
3.5.	Postupak pripreme podataka	14
4.	IMPLEMENTACIJA ALGORITMA	16
4.1.	Opis podatkovnog skupa i pretprocesiranje	16
4.2.	Anotacija podataka.	17
4.3.	Pretvorba oblaka točaka u RGB-D format.	18
4.4.	Razvojno okruženje	20
4.5.	Priprema podataka za treniranje.	21
4.6.	Implementacija arhitektura	21
4.7.	Konfiguracija treniranja.	23
4.8.	Evaluacijske metrike	25
4.9.	DFormer eksperimentalna grupa – posebnosti implementacije.	26
5.	EKSPERIMENTALNA EVALUACIJA I REZULTATI	29
5.1.	Eksperiment 1	29
5.2.	Eksperiment 2	30
5.2.1.	Kvalitativna usporedba <i>U-Net-a</i> i <i>ESANet-a</i>	32
5.2.2.	Brzina <i>inferencije</i>	35
5.3.	Eksperiment 3	35
5.3.1.	Direktna usporedba HHA naspram jednokanalne dubine	36

5.4. Eksperiment 4	38
5.4.1. Brzina <i>inferencije</i>	41
5.4.2. Detaljna analiza pogrešaka DFormer-Base modela	42
5.4.3. DFormer naspram ImageNet modela – mjerenje doprinosa prethod- nog treniranja	44
5.5. Sveobuhvatna usporedba i diskusija	45
5.5.1. Ograničenja tumačenja	47
6. ZAKLJUČAK	48
LITERATURA	50
SAŽETAK	53
ABSTRACT	54
ŽIVOTOPIS	55

1. UVOD

Razvoj precizne poljoprivrede tijekom posljednjeg desetljeća postavio je nove zahtjeve pred sustave strojnog vida koji se primjenjuju u poljoprivrednoj robotici. Jedan od najzahtjevnijih zadataka u voćarskoj proizvodnji jest rezidba, pri čemu ručna rezidba čini do 25 % ukupnih godišnjih troškova rada, osobito u nasadima jabuka i vinogradima. Istodobno, operativna i troškovna ograničenja značajno otežavaju širu primjenu tradicionalne mehanizacije u ovom procesu [1]. Zbog toga je posljednjih godina sve veći broj istraživanja usmjeren na razvoj kompaktnih robotskih platformi opremljenih sustavima strojnog vida, koje su sposobne autonomno i precizno obavljati rezidbu u složenim uvjetima voćnjaka.

Jedan od temeljnih izazova u toj domeni jest automatsko razumijevanje strukture stabla, odnosno precizno lociranje i klasifikacija grana, debla te pratećih elemenata poput potpornih stupova i žica karakterističnih za suvremene uzgojne sustave voćnjaka. Takva sposobnost preduvjet je za autonomne sustave robotske rezidbe, koji moraju pouzdano razlikovati grane predviđene za rezidbu od strukturno sličnih, ali funkcionalno posve različitih elemenata scene.

Klasični pristupi temeljeni na ručno definiranim značajkama pokazali su se nedostatnim u stvarnim uvjetima, gdje varijabilnost osvjetljenja, gustoća krošnji i međusobna okluzija grana znatno otežavaju analizu scene [2]. Uvođenjem dubokog učenja, posebice arhitektura poput potpuno konvolucijskih mreža [3] i *U-Net*-a s preskočnim vezama za očuvanje prostorne preciznosti [4], postignut je značajan napredak u razumijevanju vizualnih scena. Međutim, segmentacija temeljena isključivo na RGB podacima i dalje pati od fundamentalne dvosmislenosti u situacijama gdje objekti različitih semantičkih klasa dijele slične vizualne karakteristike – što je osobito izraženo kod potpornih žica i stupova, čiji oblik, boja i tekstura u RGB prostoru često nalikuju tankim granama, otežavajući njihovo pouzdano razlikovanje [5].

Kombiniranje podataka o boji (RGB) s informacijom o dubini scene (D) otvara put prema robusnijim sustavima percepcije [6], budući da dubinska informacija pruža prostornu komponentu neovisnu o osvjetljenju i teksturi površine, čime se u načelu omogućuje razlikovanje geometrijski različitih, ali vizualno sličnih struktura poput grana i potpornih žica. Primjena dubokog učenja na fuziji tih dvaju modaliteta aktivno je istraživačko područje [7], no ostaje nekoliko otvorenih pitanja specifičnih za domenu segmentacije grana stabala: koja je strategija integracije modaliteta dubine u arhitekturu mreže najučinkovitija [8], donosi li geometrijski eksplicitnija reprezentacija dubine mjerljivu korist za tanke, elongirane strukture, te u kojoj mjeri bazni model prethodno treniran izravno na RGB-D podacima nadmašuje uobičajenu praksu naknadne adaptacije RGB modela [9, 10]. Sustavan odgovor na ta pitanja u kontekstu voćnjaka, gdje ekstremna neravnomjernost klasa i geometrijska sličnost ciljnih struktura dodatno otežavaju zadatak, u literaturi za sada nedostaje.

Ovaj rad tu prazninu adresira eksperimentalnom usporedbom triju ortogonalnih dizajnerskih odluka na zajedničkom podatkovnom skupu i pod identičnim uvjetima evaluacije. Korišten je prošireni skup podataka *BRANCH v2*, koji sadrži RGB-D snimke krušaka u stvarnim uvjetima voćnjaka prije rezidbe, ručno i poluautomatski anotirane na razini piksela u četiri semantičke klase. Na tom je skupu evaluiran ukupno 26 konfiguracija modela kroz četiri eksperimentalne faze, koje

redom izoliraju doprinos veličine podatkovnog skupa, strategije enkodiranja dubine te paradigme prethodnog treniranja baznog modela pri čemu su prva tri eksperimenta provedena pod istovjetnim uvjetima treniranja, dok se četvrti oslanja na optimizacijski protokol preporučen u izvornim radovima *DFormer* arhitektura.

Cilj je ovog rada implementirati sustav za semantičku segmentaciju grana stabala koji je temeljen na dubokom učenju i fuziji RGB-D podataka, te sustavno ispitati doprinos ključnih dizajnerskih odluka njenoj točnosti. Konkretno, nastoji se:

- definirati skup klasa za segmentaciju koji obuhvaća grane, deblo i popratne objekte (potporne stupove, žice i ostale artefakte),
- odabrati i prilagoditi postojeće arhitekture dubokih neuronskih mreža sposobne za obradu višemodalnih RGB-D ulaza,
- provesti pripremu i anotaciju podatkovnog skupa prikladnog za navedeni zadatak,
- usporediti strategije integracije podataka o dubini te paradigme prethodnog treniranja baznog modela,
- istrenirati i evaluirati modele uz primjenu standardnih metrika za semantičku segmentaciju te utvrditi relativnu važnost istraženih faktora.

Rad je strukturiran na sljedeći način. U drugom je poglavlju dan pregled relevantnih radova iz područja semantičke segmentacije, RGB-D percepcije i arhitektura za RGB-D semantičku segmentaciju te segmentacije dijelova stabla. Treće poglavlje opisuje metodologiju, odnosno formalnu definiciju problema, strategije integracije modaliteta dubine te odabrane arhitekture mreže. Četvrto poglavlje detaljno prikazuje implementaciju: podatkovni skup i postupak anotacije, pretvorbu podataka u RGB-D format, razvojno okruženje, konfiguraciju treniranja te primijenjene evaluacijske metrike. Peto poglavlje donosi eksperimentalne rezultate kroz četiri eksperimentalne faze i njihovu raspravu, dok šesto sadrži zaključak i prijedloge za buduća istraživanja.

2. PREGLED PODRUČJA SEGMENTACIJE GRANA STABALA NA RGB-D SLIKAMA

Semantička segmentacija scene iz RGB-D slika interdisciplinarno je područje koje objedinjuje računalni vid, duboko učenje i senzorsku fuziju. Razumijevanje strukture stabla iz vizualnih podataka specifičan je i zahtjevan podzadatak, s izravnom primjenom u preciznoj poljoprivredi i autonomnoj robotici. U nastavku ovog poglavlja izlažu se ključna područja koja stoje u pozadini ovog rada: kontekst robotike u voćarstvu u kojem se problem javlja, RGB-D senzori i strategije integracije modaliteta dubine, arhitekture namijenjene RGB-D semantičkoj segmentaciji te postojeći pristupi segmentaciji dijelova stabla.

2.1. Percepcija scene u robotiziranom voćarstvu

Praktična realizacija autonomne robotske rezidbe ovisi o sposobnosti robota da vizualno razumije scenu voćnjaka. Za razliku od kontroliranih industrijskih okruženja, robot u voćnjaku djeluje na otvorenom, gdje se osvjetljenje, gustoća krošnje i geometrija stabla mijenjaju iz snimke u snimku [11]. Sposobnost pouzdanog prepoznavanja strukture stabla iz vizualnih podataka pritom je temeljni preduvjet za autonomiju: robot koji ne razlikuje granu od potporne žice, ili grančicu od debele grane, ne može donijeti smislenu odluku o rezu.

Vizualna percepcija u voćnjaku otežana je zbog nekoliko domenski specifičnih izazova. Grane i deblo dijele sličnu boju i teksturu s tlom i potpornim elementima, što uzrokuje sustavne pogreške u čistim RGB sustavima [12]. Sezonske promjene dodatno pogoršavaju situaciju: isto stablo zimi (bez lišća) i ljeti (s lišćem) daje bitno različite slike, pri čemu udio zaklonjenih grana raste s gustoćom lisnatog pokrova [13]. U gustim redovima voćnjaka česta je i međusobna isprepletenost grana susjednih stabala [14], što otežava razdvajanje pojedinačnog stabla od pozadine.

Upravo ograničenja čistog RGB modaliteta motivirala su uvođenje dubinske informacije kao komplementarnog kanala. RGB-D senzori kombiniraju sliku u boji s prostornom mapom scene, čime se vizualno slične strukture mogu razlikovati na temelju njihove geometrijske separacije [15]. Ovakav pristup posebno je pogodan za voćnjake, gdje su ciljne strukture (grane, deblo) i njihovi vizualno slični elementi scene (potporne žice, sjene) prostorno jasno razdvojene čak i kad se u RGB projekciji preklapaju.

2.2. RGB-D podaci i njihova fuzija

RGB-D (engl. *Red, Green, Blue – Depth*) senzori kombiniraju standardnu kameru u boji s modulom za mjerenje dubine, pa scenu opisuju dvama modalitetima, bojom i dubinom. Pod modalitetom se u ovom radu podrazumijeva jedna vrsta ulazne informacije o sceni, dobivena zasebnim mjerenjem i s vlastitim statističkim svojstvima. U praksi dominiraju tri različite tehnologije. Strukturirano svjetlo projicira infracrveni uzorak na scenu i računa dubinu triangulacijom, čime se osigurava visoka točnost na kraćim udaljenostima uz osjetljivost na sunčevu svjetlost. Upravo se ova tehnologija koristi u senzoru *Asus Xtion Pro* primijenjenom za prikupljanje podataka u ovom radu.

Alternativu predstavljaju senzori temeljeni na mjerenju vremena leta (engl. *Time of Flight*, ToF), koji nude visoku frekvenciju snimanja, ali su podložni pogreškama zbog višestrukog odbijanja signala (engl. *multipath interference*) [16]. Treću skupinu čini pasivni stereo vid koji dubinu procjenjuje iz paralakse između dviju kamera, zbog čega izravno ovisi o izraženosti teksture površine [17].

Sirove dubinske mape rijetko su spremne za izravnu upotrebu. One tipično sadrže nedostajuće vrijednosti (engl. *holes*) na prozirnim i zrcalnim površinama, u područjima okluzije te izvan dometa senzora, što zahtijeva korake preprocesiranja i interpolacije [18]. Dodatan izazov predstavlja geometrijsko poravnavanje (engl. *registration*) RGB podataka i podataka o dubini, nužno zbog različitih optičkih osi senzora. Oba problema posebno su izražena u otvorenom prostoru poput voćnjaka, gdje sunčeva svjetlost dodatno narušava pouzdanost infracrvenih mjerenja.

Gupta i sur. [19] uveli su HHA (engl. *Horizontal disparity, Height above ground, Angle with gravity*) enkodiranje dubine – jedan od najutjecajnijih doprinosa u području obrade RGB-D podataka. HHA jednokanalnu dubinsku mapu transformira u trokanalnu sliku, koja kodira horizontalni odmak kao mjeru relativne udaljenosti objekta od kamere, visinu iznad tla dobivenu iz geometrijskog modela scene te kut između normale lokalne površine i vektora gravitacije. Ovakvo enkodiranje posebno je korisno za razlikovanje vertikalnih struktura (debla, stupovi) od horizontalnih (tlo, horizontalne žice), što je izravno relevantno za segmentaciju voćnjaka. Digumarti i sur. [5] pokazali su da HHA enkodiranje, u kombinaciji s kasnom fuzijom (engl. *late fusion*), postiže bolje rezultate od rane fuzije pri segmentaciji stabala. U takvom pristupu RGB i HHA grane obrađuju informacije odvojeno i spajaju se tek na razini dubokih značajki. Razlog boljeg rezultata leži u činjenici da debla i grane imaju karakteristične geometrijske oblike (cilindrične površine) koji su eksplicitno prikazani u HHA kanalima.

U literaturi se razlikuju tri temeljne kategorije fuzijskih strategija [8]. Rana fuzija (engl. *early fusion*) dubinsku mapu spaja s RGB kanalima u četverokanalni tenzor ($H \times W \times 4$) na samom ulazu. Pristup je jednostavan i izravno primjenjiv na postojeće RGB arhitekture, no miješa modalitete na najnižoj razini apstrakcije prije nego mreža razvije reprezentacije specifične za pojedini modalitet. Kasna fuzija (engl. *late fusion*) koristi paralelne enkoder grane za svaki modalitet, koje se spajaju tek neposredno prije glave za segmentaciju. Time se omogućuje učenje modalitet-ski specifičnih značajki, ali se gubi prostorna sinergija uslijed postupnog smanjenja rezolucije. Međurazinska fuzija (engl. *mid-level fusion*) provodi izmjenu informacija na više razina apstrakcije unutar mreže, tipično kroz međumodalne mehanizme pažnje, čime osigurava selektivno vođenje informacije te robusnost na šum i nepotpune dubinske podatke [8].

Reprezentativan primjer napredne međumodalne fuzije predstavlja okvir *Cross-Modal eXchange* (CMX) [8], koji uvodi dva komplementarna modula: modul za ispravljanje međumodalnih značajki (engl. *Cross-Modal Feature Rectification Module*, CM-FRM) i modul za spajanje značajki (engl. *Feature Fusion Module*, FFM). CM-FRM na svakoj razini hijerarhije enkodiranja kalibrira značajke jednog modaliteta koristeći informacije iz drugoga, i to u prostornoj i kanalnoj dimenziji. FFM zatim, na temelju tako kalibriranih značajki, primjenjuje mehanizam unakrsne pažnje (engl. *cross-attention*) za razmjenu dugodosežnog konteksta između modaliteta na globalnoj ra-

zini. CMX je verificiran na pet referentnih RGB-D skupova podataka, čime je pokazano da objedinjeni međumodalni pristup nadmašuje metode specifične za pojedini modalitet.

2.3. Arhitekture za RGB-D semantičku segmentaciju

Arhitekture se razlikuju po tome na kojim je podacima njihov bazni model (engl. *backbone*) prethodno treniran. U prvu skupinu ulaze mreže čiji je bazni model prethodno treniran isključivo na RGB slikama (*ImageNet*), pa se dubinska informacija u njega uvodi naknadno, proširenjem ulaznog sloja ili zasebnom dubinskom granom. U drugu skupinu ulaze mreže čiji je bazni model već u fazi prethodnog treniranja učio na parovima RGB slike i dubinske mape. U obje skupine model se zatim fino podešava na ciljnom zadatku; razlikuju se samo po polazišnoj reprezentaciji.

Prvu skupinu reprezentira *ESANet* (engl. *Efficient Scene Analysis Network*) [20], mreža dizajnirana za učinkovitu semantičku segmentaciju RGB-D scena. Koristi dvije odvojene grane enkodera za RGB i dubinu, inicijalizirane iz istog RGB modela (*ResNet-34* ili *ResNet-50*) prethodno treniranog na skupu *ImageNet*. Dubinski enkoder prima jednokanalnu sliku, pa se težine njegova prvog konvolucijskog sloja dobivaju kao prosjek težina triju ulaznih kanala prethodno treniranog RGB modela, prema izrazu (3-6). Time jednokanalni ulaz nasljeđuje već naučene filtre rubova i tekstura umjesto da kreće od slučajne inicijalizacije. Značajke se spajaju na svakoj razini hijerarhije kroz *Squeeze-and-Excitation* (SE) fuzijske blokove koji adaptivno ponderiraju kanale, a lagani dekodekter rekonstruira prostornu rezoluciju uz preskočne veze. *ESANet* postiže konkurentne rezultate na skupovima *NYUv2* i *SUN RGB-D*, što ga čini praktičnim izborom kada je cilj brza prilagodba prethodno treniranih RGB modela na RGB-D ulaz bez skupog prethodnog treniranja cijelog baznog modela na RGB-D podacima.

Drugu skupinu čine arhitekture obitelji *DFormer* (engl. *Depth-aware Transformer*), koje uvode značajan iskorak: bazni model koji je od početka zajednički prethodno treniran na velikim RGB-D skupovima. *DFormer* [9] prethodno se trenira zadatkom predviđanja prikrivenih regija (engl. *masked autoencoder*) na kombiniranim RGB i dubinskim ulazima. Uvodi i modul *Depth-aware Attention* (DAA), koji izračunava pažnju između tokena ovisno o njihovoj prostornoj blizini u dubinskom prostoru. Pikseli koji su bliski u 3D prostoru trebali bi imati jaču međusobnu pažnju, što je izravno korisno za međusobno zaklonjene strukture poput isprepletenih grana. Temeljna hipoteza ovog pristupa jest da zajedničko prethodno treniranje razvija reprezentacije koje izravno obuhvaćaju prostorne geometrije scene.

Njegov nasljednik *DFormer v2* [10] zadržava istu paradigmu prethodnog treniranja, ali uvodi mehanizam diferencijalne unakrsne pažnje (engl. *differential cross-attention*) za razlikovanje vizualno sličnih, ali geometrijski različitih objekata. Sadrži i višerazmjernu fuzijsku glavu (engl. *multi-scale fusion head*) s adaptivnim težinama koje se uče zasebno za svaku razinu i segment slike, uz poboljšanu strategiju prethodnog treniranja s većim omjerima prikrivanja. Usporedbe s v1 pokazuju konzistentno poboljšanje mIoU metrike (engl. *mean Intersection over Union*) u rasponu 1,5 – 3,2 postotna boda. Najveći dobitak pritom je zabilježen upravo na tankim i izduženim strukturama, što je izravno relevantno za segmentaciju grana.

2.4. Segmentacija dijelova stabla

Pojam segmentacije strukture stabla u ovom radu podrazumijeva prepoznavanje grana u odnosu na deblo stabla i tanke potporne žice. Složenost ovog problema jest u fizičkoj sličnosti grana i potpornih žica. Dodatan problem predstavlja neravnomjernost klasa u podatkovnim skupovima jer potporne žice čine izuzetno mali udio ukupnog broja piksela, u odnosu na grane koje dominiraju scenom. Također, grane su često međusobno isprepletene, posebno u gustim redovima voćnjaka [14]. Kako su stabla podložna promjeni, dodatnu složenost čini i sezonska promjena: udio zaklonjenih grana raste s gustoćom lisnatog pokrova [13]. Naposljetku, kora dijeli sličnu boju i teksturu s tlom ili potpornim žicama, što stvara sistemsku dvosmislenost u čistim RGB sustavima [5].

Rani sustavi za segmentaciju vegetacije oslanjali su se na klasične tehnike računalnog vida i geometrijsko modeliranje trodimenzionalnih (3D) oblaka točaka. Detekcija rubova Cannyjevim algoritmom, Houghova transformacija te 3D podaci dobiveni sustavima LIDAR (engl. *Light Detection and Ranging*) činili su tehnološku osnovu tih pristupa. Reprezentativan primjer jest algoritam *TreeQSM* [21], koji modelira strukturu stabla iz gustih oblaka točaka prilagođavanjem cilindričnih segmenata, čime se postižu detaljni 3D modeli grananja. Takav pristup odlikuje se visokom preciznošću, ali i visokom računalnom zahtjevnošću, zbog čega je neprikladan za rad u realnom vremenu.

Rano rješenje vođeno podacima (engl. *data-driven*) za segmentaciju oblaka točaka vegetacije predloženo je u [22]. Za razliku od *TreeQSM*-a, taj pristup ne dijeli podatke na skup geometrijskih primitiva poput cilindra, već obradu provodi izravno na razini samog oblaka. Konkretno, izdvaja se mezo-skelet (engl. *meso-skeleton*) uporabom modificiranog algoritma *Deep Points Consolidation*. Potom se za svaku točku oblaka izračunavaju vektori zakrivljenosti površine u adaptivnim sfernim susjedstvima, čiji se polumjer skalira proporcionalno s udaljenošću točke od skeleta. Klasifikator *Random Forest* treniran na sintetičkim podacima postiže prosječnu točnost klasifikacije između 87 % i 95 % na simuliranim listopadnim stablima, s generalizacijom na neviđene vrste. Bio je to jedan od prvih pristupa koji je demonstrirao segmentaciju vegetacije vođenu podacima bez potrebe za ručnim podešavanjem pragova.

Ključan pomak prema segmentaciji izravno iz RGB-D slika, a ne iz oblaka točaka, donio je pristup koji svaki piksel pojedinačne RGB-D snimke klasificira u kategorije deblo, grana, grančica ili list [5]. Osim nalaza o prednosti kasne fuzije, navedenog u potpoglavlju 2.2, taj rad uvodi i asinkrono treniranje (engl. *asynchronous training*), u kojem se RGB grana i HHA grana treniraju zasebno, uz različite stope učenja za različite dijelove mreže. Mreža koja dubinu tretira kao četvrti ulazni kanal pritom znatno zaostaje za pristupom kasne fuzije, što upućuje na to da su modaliteti previše različiti da bi ih mreža naučila iz zajedničkog ulaza bez prethodnog razvijanja reprezentacija specifičnih za pojedini modalitet. Evaluacija je provedena na sintetičkom skupu od 28 800 slika šest vrsta lisnatih stabala, uz kvalitativnu demonstraciju na stvarnim snimkama prikupljenim senzorom *Kinect*.

Nakon tih radova područje se sve bliže usmjeravalo domenskim primjenama u voćnjaku. Za segmentaciju okluziranih grana iz RGB-D podataka predložena je metoda koja duboko učenje kombinira s geometrijskim ograničenjima izvedenim iz dubinske mape, s ciljem rekonstrukcije di-

jelova grana zaklonjenih lišćem [15]. Primjena konvolucijskih mreža na segmentaciju debla i grana jabuka u uzgojnim sustavima s potpornom konstrukcijom istražena je s naglaskom na robusnost modela na promjenu uvjeta snimanja između sezona [23]. Za kruške je pak razvijen sustav koji kombinira poboljšanu instancijsku segmentaciju temeljenu na modelu *YOLOv8n-seg* s dinamičkim konvolucijama prilagođenima hvatanju izduženih struktura; postiže srednju prosječnu preciznost (engl. *mean Average Precision*, mAP) od 82,6 % za segmentaciju uspravnih grana u stvarnim uvjetima voćnjaka, iako je rezultat samo indikativno usporediv jer se odnosi na instancijsku, a ne semantičku segmentaciju [14].

Uz spomenute pristupe temeljene na slikama, u literaturi postoje i arhitekture koje izravno obrađuju 3D oblake točaka bez potrebe za vokselizacijom. Modeli poput *PointNet* [24] i *PointNet++* [25] koriste globalno i hijerarhijsko grupiranje točaka, a njihova primjena na segmentaciju strukture stabala pokazala je obećavajuće rezultate. Međutim, ovi modeli zahtijevaju guste i poravnate oblake, pa nisu izravno primjenjivi na standardne RGB-D okvire prikupljene u realnom vremenu.

2.5. Odabir arhitekture i motivacija

Eksperimentalna evaluacija u ovom radu podijeljena je u dvije faze, s ciljem sustavnog ispitivanja utjecaja strategije prethodnog treniranja. U prvoj fazi evaluirani su modeli s baznim modelima prethodno treniranim isključivo na RGB podacima (*ImageNet*), uz naknadnu integraciju modalitet dubine različitim strategijama fuzije. U tu skupinu ulaze konvolucijska arhitektura *U-Net* s *ResNet-34* i *EfficientNet-B4* baznim modelima, *DeepLabV3* s *ResNet-50* i *DeepLabV3+* s *MobileNetV2*, *SegFormer-B1*, *MA-Net* s *ResNeXt-50* te *Pix2Pix* generator. Kao jedini predstavnik koji je od temelja projektiran za RGB-D ulaz s paralelnim granama, ali s baznim modelima prethodno treniranim na *ImageNet*-u odabran je *ESANet* [20].

Uz standardnu ranu fuziju (proširenje ulaznog sloja na 4 kanala) istraženo je i HHA enkodiranje [19] kao alternativna reprezentacija dubine. Izbor je motiviran nalazima iz [5], koji pokazuju da HHA bolje kodira geometrijske karakteristike relevantne za segmentaciju drvenastih struktura. U drugoj fazi evaluirani su *DFormer* [9] i *DFormer v2* [10] s izvornim prethodnim treniranjem na RGB-D podacima. Cilj druge faze jest kvantificiranje doprinosa geometrijski svjesnog prethodnog treniranja u odnosu na naknadnu adaptaciju RGB modela.

2.6. Sinteza pregleda

Pregled literature otkriva nekoliko ključnih uvida koji izravno oblikuju eksperimentalni pristup ovog rada. Semantička segmentacija dijelova stabla iz RGB-D slika je zahtjevniji zadatak od standardnih segmentacijskih *benchmarkova* poput *NYUv2* ili *SUN RGB-D*. Tankoća grana, velika neravnomjernost klasa i vizualna sličnost kore drveta s pozadinom postavljaju visoke zahtjeve na prostornu preciznost modela. Istodobno, sezonske varijacije i isprepletena geometrija voćnjaka naglašavaju važnost dubinske informacije kao komplementarnog modaliteta [13, 14].

Literatura pokazuje i da način na koji se modalitet dubine integrira nije trivijalan izbor. Rana

fuzija na razini ulaznog tenzora konzistentno zaostaje za pristupima koji razvijaju modalitetski specifične reprezentacije prije spajanja [5]. HHA enkodiranje [19] pritom nudi geometrijski bogatiju alternativu jednokanalnoj dubinskoj mapi, i to upravo za domene s karakterističnim cilindričnim strukturama poput grana i debla.

Uvođenje baznih modela prethodno treniranih izravno na RGB-D podacima predstavlja alternativu naknadnoj adaptaciji RGB modela [9, 10]. Doprinos ovog pristupa na domenski specifičnim skupovima podataka, poput voćnjaka, još je nedovoljno istražen. Većina radova koji uspoređuju fuzijske strategije oslanja se na generičke skupove zatvorenih prostora. Pri čemu se njihovi zaključci ne moraju izravno prenositi na scene voćnjaka s ekstremnom neravnomjernošću klasa, tankim strukturama i vanjskim uvjetima osvjetljenja.

Na temelju ovih uvida, evaluacija u ovom radu strukturirana je u dvije komplementarne faze. Prva sustavno ispituje granice baznih modela prethodno treniranih na *ImageNet* skupu podataka, uz različite strategije integracije dubine, uključujući HHA enkodiranje. Druga kvantificira doprinos prethodnog treniranja na RGB-D podacima kroz *DFormer* arhitekture. Ovakav dizajn omogućuje izoliranu procjenu doprinosa svake pojedinačne komponente strategije fuzije, enkodiranja dubine i paradigme prethodnog treniranja, što do sada nije sustavno istraženo u kontekstu segmentacije grana voćnih stabala.

3. METODOLOGIJA

Ovaj rad pristupa problemu semantičke segmentacije grana stabala kao zadatku nadgledanog dubokog učenja na RGB-D slikama. U nastavku je opisan formalni okvir problema, konceptualni opis odabranih arhitektura i matematički modeli koji čine osnovu predloženog rješenja.

3.1. Teorijska pozadina

U ovom potpoglavlju se izlažu ključni koncepti dubokog učenja primijenjeni u ovom radu: matematička formulacija zadatka semantičke segmentacije, mehanika rezidualnih blokova i prijenosnog učenja korištena u konvolucijskim baznim modelima, princip proširenih konvolucija i višerazmjernog konteksta te mehanizam samopažnje kao osnova transformatorskih arhitektura.

Formalno, za ulaznu sliku $I \in \mathbb{R}^{H \times W \times C}$ (gdje su H i W visina i širina, a C broj kanala), cilj semantičke segmentacije je naučiti funkciju $f : \mathbb{R}^{H \times W \times C} \rightarrow \{1, \dots, K\}^{H \times W}$ koja za svaki piksel predviđa jednu od K semantičkih klasa [3]. Za razliku od klasifikacije i detekcije objekata, ova funkcija proizvodi gustu predikciju na razini piksela i ne razlikuje pojedinačne instance iste klase. Složenost zadatka proizlazi iz kompromisa između globalnog semantičkog razumijevanja, koje uvjetuje veće receptivno polje, i precizne lokalizacije granica koja zahtijeva očuvanje visoke prostorne rezolucije.

Rezidualne mreže (*ResNet*) uvele su rezidualne blokove koji uče funkciju $F(x) = H(x) - x$, što omogućuje izravno propagiranje gradijenata kroz vrlo duboke mreže [26]. *ResNet-34* koristi osnovne blokove s dvjema 3×3 konvolucijama, dok *ResNet-50* i *ResNet-101* koriste blokove uskog grla (engl. *bottleneck*) sa slojevima 1×1 , 3×3 i 1×1 konvolucija koji smanjuju računalno opterećenje. Prethodno treniranje (engl. *pre-training*) na skupu podataka *ImageNet* pruža inicijalizaciju parametara koja se u praksi pokazala superiornom nad slučajnom inicijalizacijom [27], što je posebno važno u uvjetima ograničene količine ciljnih podataka, posebno u domenama poput poljoprivrede.

Proširene (engl. *atrous / dilated*) konvolucije uvode parametar proširenja d koji povećava receptivno polje bez smanjenja prostorne rezolucije i bez povećanja broja parametara. Za jednodimenzionalni signal, izlaz proširene konvolucije $y[i]$ računa se kao:

$$y[i] = \sum_{k=1}^K x[i + d \cdot k] \cdot w[k] \quad (3-1)$$

gdje x označava ulaz, w filter, a K veličinu filtera. Modul ASPP koji se koristi u arhitekturi *DeepLabv3+* [28] paralelno primjenjuje proširene konvolucije s više različitih stopa proširenja, čime jedan sloj istodobno obuhvaća kontekste više prostornih razmjera.

Mehanizam samopažnje temelji se na izračunu težinskih koeficijenata između svih parova elemenata ulaznog niza. Za niz od N tokena, samopažnja se računa kao [29]:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (3-2)$$

gdje su Q , K i V matrice upita (engl. *query*), ključa (engl. *key*) i vrijednosti (engl. *value*) dobivene linearnim projekcijama ulaza, a d_k dimenzija ključa. Arhitektura *SegFormer* [30] koristi komponentu *Mix-FFN* (engl. *Mixed Feed-Forward Network*) koja uvodi konvolucijsku operaciju unutar transformatorskih blokova, čime se implicitno kodira pozicijska informacija bez potrebe za eksplicitnim pozicijskim kodiranjem. Arhitektura *Mask2Former* [31] nadalje uvodi mehanizam maskirane pažnje (engl. *masked attention*) koji ograničava pažnju upita na predviđenu regiju interesa, čime se ubrzava konvergencija i poboljšava kvaliteta segmentacije.

3.2. Definicija problema

Semantička segmentacija grana stabala iz RGB-D slika formulira se kao zadatak guste klasifikacije na razini piksela. Formalno, za ulazni par (I_{RGB}, I_D) gdje $I_{RGB} \in \mathbb{R}^{H \times W \times 3}$ označava RGB sliku visine H i širine W , a $I_D \in \mathbb{R}^{H \times W \times 1}$ odgovarajuću dubinsku mapu, cilj je naučiti funkciju:

$$f_\theta : \mathbb{R}^{H \times W \times C} \rightarrow \{0, 1, 2, 3\}^{H \times W} \quad (3-3)$$

koja za svaki piksel predviđa jednu od $K = 4$ semantičkih klasa: pozadinu (0), deblo (1), grane (2) i potporu (3). Parametar C označava broj ulaznih kanala i ovisi o strategiji integracije modaliteta dubine: $C = 4$ za ranu fuziju s jednokanalnom dubinom ili $C = 6$ za HHA enkodiranje dubine.

Izlaz mreže je tenzor dimenzija $[B \times K \times H \times W]$ iz kojeg se finalna maska segmentacije dobiva primjenom *argmax* operacije duž dimenzije klasa za svaki piksel:

$$\hat{y}(i, j) = \underset{k \in \{0, \dots, K-1\}}{\operatorname{argmax}} [f_\theta(x)]_{k,i,j} \quad (3-4)$$

gdje x označava ulazni tenzor, a $[f_\theta(x)]_{k,i,j}$ nenormaliziranu izlaznu vrijednost mreže (engl. *logit*) za klasu k na poziciji (i, j) . Riječ je o vrijednosti prije primjene funkcije *softmax*, pa nije ograničena na raspon $[0, 1]$ niti se po klasama zbraja u jedinicu. Kako *softmax* ne mijenja poredak vrijednosti, operacija *argmax* može se primijeniti izravno na njih.

Izbor i definicija semantičkih klasa motivirani su zahtjevima primjene autonomne rezidbe i vizualnim karakteristikama scena voćnjaka. Definirane su četiri klase:

- Pozadina (klasa 0) obuhvaća sve vizualne elemente koji nisu dio stabla: nebo, tlo, susjedna stabla i ostali šum. Dominira brojem piksela u tipičnoj sceni voćnjaka, što uzrokuje izraženu neravnomjernost distribucije klasa.
- Deblo (klasa 1) obuhvaća glavni vertikalni element stabla od tla do mjesta prvog grananja. Geometrijski je karakterizirano većim promjerom i dominantnom vertikalnom orijentacijom. Premda nije direktan predmet rezidbe, deblo služi kao prostorna referenca za određivanje položaja stabla.
- Grane (klasa 2) obuhvaćaju sve lateralne elemente koji se granaju od debla – primarne, sekundarne i tercijarne grane – neovisno o promjeru ili orijentaciji. Ovo je klasa od primarnog interesa jer grane predstavljaju glavni predmet procjene rezidbe.

- Potpora (klasa 3) obuhvaća betonske potporne vertikalne stupove te horizontalne metalne žice karakteristične za uzgojne sustave voćnjaka. Metalne žice u ovoj klasi imaju vizualne i geometrijske sličnosti tankim granama, što je jedan od ključnih izvora pogrešne klasifikacije u čistim RGB sustavima.

Budući da su anotacije prikupljene u 3D prostoru, a modeli segmentacije rade u 2D prostoru slike, neophodna je projekcija anotiranih 3D točaka na ravninu slike. Matematička osnova jest standardni model perspektivne kamere. Za točku $P = (X, Y, Z)$ u koordinatnom sustavu kamere, koordinate odgovarajućeg piksela (u, v) računaju se kao:

$$u = F_X \cdot \frac{X}{Z} + C_X, \quad v = F_Y \cdot \frac{Y}{Z} + C_Y \quad (3-5)$$

gdje su F_X, F_Y žarišne duljine u pikselima, a C_X, C_Y koordinate optičkog centra kamere. U slučaju da više 3D točaka projicira na isti piksel, primjenjuje se *Z-buffer* pristup kojim se zadržava oznaka točke najbliže senzoru, što je konzistentno s načinom na koji kamera bilježi scenu.

Izazovi opisani u potpoglavlju 2.4, imaju izravne posljedice za dizajn segmentacijskog sustava i motiviraju tri konkretna metodološka izbora u ovom radu. Prva posljedica odnosi se na razlikovanje geometrijski različitih, ali vizualno sličnih klasa. Grane i potporne žice u 2D projekciji dijele linearan oblik i sličan raspon boja, no u 3D prostoru se razlikuju: žice se protežu horizontalno u konstantnoj ravnini, dok grane zauzimaju heterogene dubinske raspone. Ovo motivira sustavno ispitivanje strategija integracije modaliteta dubine, opisano u potpoglavlju 3.3. Druga posljedica proizlazi iz izražene neravnomjernosti klasa. Standardna unakrsna entropija, koja tretira sve piksele jednako, teži zanemarivanju rijetkih klasa poput grana i potpore u korist brojčano dominantne pozadine. Iz tog razloga se pri treniranju modela koriste kombinirane funkcije gubitka, detaljno opisane u potpoglavlju 4.7. Treća posljedica veže se za tanku i izduženu prirodu ciljnih struktura. Agresivno smanjivanje prostorne rezolucije u enkoderima uzrokuje gubitak finih detalja koji su za segmentaciju grana ključni. Ovo motivira usmjerenost na arhitekture s mehanizmima očuvanja rezolucije s preskočnim vezama, višerazmjernim modulima ili hijerarhijskim transformatorskim enkoderima – što je detaljnije razrađeno u potpoglavlju 3.4.

3.3. Strategije integracije modaliteta dubine

Središnje istraživačko pitanje ovog rada jest kako optimalno integrirati modalitet dubine u arhitekturu segmentacijske mreže. Razmatraju se tri konceptualno različite strategije, od kojih svaka ima različite implikacije na sposobnost mreže da razvije reprezentacije specifične za pojedini modalitet.

3.3.1. Rana fuzija s jednokanalnom dubinom

Najjednostavnija strategija tretira jednokanalnu dubinu, odnosno dubinsku mapu izmjerenu senzorom i normaliziranu na raspon $[0, 1]$, bez geometrijske transformacije, kao dodatni kanal koji se spaja s RGB kanalima na ulazu mreže, formirajući četverokanalni tenzor $x \in \mathbb{R}^{B \times 4 \times H \times W}$. Ulazni konvolucijski sloj prethodno treniranog baznog modela proširuje se s 3 na 4 kanala, pri čemu se

težine dodatnog kanala inicijaliziraju prosjekom težina RGB kanala kako bi se osigurala stabilna inicijalizacija:

$$W_{in}^{(4)} = \frac{1}{3} \sum_{c=1}^3 W_{in}^{(c)} \quad (3-6)$$

Prednost ovog pristupa jest jednostavnost i izravna primjenjivost na sve standardne arhitekture. Nedostatak jest što mreža mora istovremeno naučiti korisne reprezentacije iz vizualno heterogenih modaliteta od prvog sloja, bez mogućnosti prethodnog treniranja za pojedini modalitet.

3.3.2. HHA enkodiranje dubine

Alternativna strategija zamjenjuje neobrađenu dubinu trokanalnom HHA reprezentacijom [19], formirajući šesterokanalni ulaz $x \in \mathbb{R}^{B \times 6 \times H \times W} = \text{RGB} (3) + \text{HHA} (3)$. HHA enkodiranje jedнокanalnu dubinsku mapu transformira u tri kanala s jasnim geometrijskim značenjem:

$$\text{HHA} = \begin{bmatrix} d_{\text{horiz}} \\ h_{\text{ground}} \\ \alpha_{\text{gravity}} \end{bmatrix} \quad (3-7)$$

gdje d_{horiz} označava horizontalni disparitet (recipročan dubini) od kamere u horizontalnoj ravnini, h_{ground} visinu točke iznad procijenjene ravnine tla, a α_{gravity} kut između normale lokalne površine i vektora gravitacije. Ova reprezentacija eksplicitno kodira geometrijske karakteristike relevantne za razlikovanje vertikalnih struktura (debla, stupovi) od horizontalnih (tlo, žice) i cilindričnih (grane), što je posebno korisno u domeni voćnjaka [5].

3.3.3. Paralelne enkoder grane (ESANet pristup)

Sofisticiranija strategija koristi dvije odvojene enkoder grane od kojih je jedna za RGB, a druga za modalitet dubine. One procesiraju modalitete neovisno i spajaju ih na više razina hijerarhije kroz fuzijske module. Formalno, na razini l hijerarhije enkodiranja, spojene (engl. *fused*) značajke računaju se kao:

$$f_l^{\text{fused}} = \mathcal{F}_l(f_l^{\text{RGB}}, f_l^D) \quad (3-8)$$

gdje $\mathcal{F}_l$ označava fuzijski modul na razini l . U *ESANet* arhitekturi [20] $\mathcal{F}_l$ je implementiran kao *Squeeze-and-Excitation* (SE) modul koji uči adaptivne kanalne težine:


$$(w_l^{\text{RGB}}, w_l^D) = \text{SE} \left(\begin{bmatrix} f_l^{\text{RGB}}; f_l^D \end{bmatrix} \right) \quad (3-9)$$

$$f_l^{\text{fused}} = w_l^{\text{RGB}} \cdot f_l^{\text{RGB}} + w_l^D \cdot f_l^D \quad (3-10)$$

Ovaj pristup omogućuje da svaka grana nauči značajke prilagođene svojem modalitetu uz istodobnu međumodalnu razmjenu informacija na više razina apstrakcije.

3.3.4. Prethodno treniranje na RGB-D podacima (DFormer pristup)

Fundamentalno drugačija strategija temelji se na baznom modelu koji je od temelja prethodno treniran na RGB-D podacima kroz *self-supervised masked autoencoder* zadatak [9, 10]. Za razliku od klasičnog pristupa u kojem se dubinska informacija uvodi tek u fazi finog podešavanja, *DFormer* provodi prethodno treniranje baznog modela izravno na RGB-D podacima, čime se stvara jedinstveni enkoder koji od početka uči zajedničku RGB-D reprezentaciju. Konceptualna razlika između klasične i *DFormer* paradigme prikazana je na slici 3.1.



Sl. 3.1: Usporedba klasične RGB paradigme prethodnog treniranja (gore) i RGB-D specifičnog prethodnog treniranja koju uvodi *DFormer* (dolje). U klasičnoj paradigmi bazni model je prethodno treniran isključivo na RGB podacima (npr. ImageNet), a modalitet dubine integrira se tek u fazi finog podešavanja pomoću zasebne dubinske grane s *Interaction* modulom za fuziju. *DFormer* umjesto toga provodi prethodno treniranje baznog modela izravno na RGB-D podacima (NYU Depth v2 i SUN RGB-D), čime se stvara jedinstveni enkoder koji od početka uči zajedničku RGB-D reprezentaciju. Preuzeto iz [9].

Umjesto *post-hoc* adaptacije RGB modela, *DFormer* implementira *Depth-aware Attention* (DAA) mehanizam koji izračunava pažnju između tokena uzimajući u obzir njihovu prostornu blizinu u dubinskom prostoru. Za par tokena i i j , modificirana pažnja računa se kao:

$$\text{Attn}_{\text{DAA}}(i, j) = \text{softmax} \left(\frac{q_i k_j^T}{\sqrt{d}} + \phi(|z_i - z_j|) \right) \quad (3-11)$$

gdje z_i, z_j označavaju dubinske vrijednosti tokena, a ϕ je naučena funkcija koja penalizira pažnju između prostorno udaljenih tokena. Ova formulacija osigurava da mreža razvije geometrijski svjesne reprezentacije koje su po svojoj prirodi multimodalne, a ne tek adaptacija RGB modela.

3.4. Odabrane arhitekture

Na temelju pregleda literature i definiranog istraživačkog pitanja, evaluirane arhitekture podijeljene su u dvije eksperimentalne grupe prema strategiji prethodnog treniranja baznog modela.

3.4.1. Prva eksperimentalna grupa

Prvu grupu čine modeli s baznim modelom prethodno treniranim isključivo na RGB podacima (*ImageNet*), kojima je modalitet dubine naknadno integriran jednom od strategija opisanih u poglavlju 3.3.

U-Net [4] koristi simetričnu enkoder-dekoder strukturu s preskočnim vezama koje prenose niskoslojne prostorne informacije direktno u dekoder, čuvajući prostornu preciznost neophodnu za segmentaciju tankih struktura. Evaluirani su bazni modeli *ResNet-34* i *EfficientNet-B4*.

DeepLabV3 [28] koristi *Atrous Spatial Pyramid Pooling* (ASPP) modul s proširenim konvolucijama stopa proširenja 6, 12 i 18 za višerazmjerno hvatanje konteksta bez smanjenja prostorne rezolucije. *DeepLabV3+* proširuje ovaj pristup dekoderom s preskočnim vezama. Evaluirani su bazni modeli *ResNet-50* i *MobileNetV2*.

SegFormer [30] uvodi hijerarhijski *transformer* enkoder koji generira višerazmjerne značajke i MLP dekoder s malim brojem parametara. Odabran je model veličine *B1* koji nudi povoljan kompromis između izražajnosti i računalne učinkovitosti.

MA-Net (*Multi-scale Attention Network*) koristi višerazmjernu pažnju u dekoderu koja selektivno naglašava relevantne prostorne regije na svakoj razini dekodiranja. Evaluiran je s baznim modelom *ResNeXt-50_32×4d*.

Pix2Pix [32] je generativni adversarni model koji kombinira *U-Net* generator s *PatchGAN* diskriminatorom. Uključen je kao nekonvencionalni referentni model (engl. *baseline*) koji segmentaciju tretira kao zadatak prevođenja slike u sliku (*image-to-image translation*). Evaluirane su dvije varijante: s punim suparničkim treniranjem i bez diskriminatora.

ESANet [20] jedina je arhitektura u ovoj grupi dizajnirana od temelja za RGB-D ulaz s paralelnim enkoder granama i *SE*-fuzijskim modulima, opisana u poglavlju 3.3.3.

3.4.2. Druga eksperimentalna grupa

Drugu grupu čine *DFormer v1* [9] i *DFormer v2* [10] čiji su bazni modeli prethodno trenirani na RGB-D podacima (*NYU Depth v2* i *SUN RGB-D*) kroz *masked autoencoder* zadatak, opisani konceptualno u potpoglavlju 3.3.4. Evaluirane su tri veličine svake generacije: *Small*, *Base* i *Large*.

3.5. Postupak pripreme podataka

RGB kanali normalizirani su *ImageNet* statistikama kako bi bili kompatibilni s prethodno treniranim baznim modelima:

$$x_{norm}^{(c)} = \frac{x^{(c)} - \mu_c}{\sigma_c}, \mu = [0.485, 0.456, 0.406], \sigma = [0.229, 0.224, 0.225] \quad (3-12)$$

Dubinska mapa normalizirana je rezanjem na maksimalnu vrijednost $d_{\max} = 4.0$ m, što odgovara tipičnoj maksimalnoj udaljenosti stabla od senzora u uvjetima snimanja u voćnjaku, i skaliranjem na raspon $[0, 1]$:

$$d_{norm} = \frac{\text{clip}(d, 0, d_{\max})}{d_{\max}} \quad (3-13)$$

Kritičan aspekt dizajna eksperimenata jest sprječavanje curenja podataka (engl. *data leakage*). Budući da su višestruke slike istog stabla snimljene iz različitih kutova gledišta, naivna nasumična podjela na razini pojedinih slika uzrokovala bi situaciju u kojoj slike istog stabla istovremeno ulaze u skupove za treniranje i testiranje. To bi rezultiralo precijenjenim metrikama koje ne odražavaju stvarnu sposobnost generalizacije modela na neviđena stabla. Podjela je stoga provedena na razini stabala u omjeru 70:15:15 (treniranje, validacija, testiranje), pri čemu je jamčeno da nijedno stablo ne nastupa u više od jednog skupa. Nadalje, skupovi za validaciju i testiranje sadrže isključivo anotacije usporedive s ručno anotiranom kvalitetom odnosno, grupa A, B i D (vidi 4.2). Grupa C isključena je iz validacije i testiranja jer je generirana ranijom verzijom modela čije su inicijalne predikcije zahtijevale opsežnije ručne korekcije, pa se ne može jamčiti ista razina kvalitete kao kod ostalih grupa. Grupa D, iako također poluautomatski generirana, proizvedena je poboljšanim modelom čije su predikcije uz manje korekcije dosegle kvalitetu usporedivu s potpuno ručnom anotacijom, zbog čega je uključena u validaciju i testiranje. Detaljni opis grupa nalazi se u poglavlju 4.2.

Augmentacija podataka primjenjuje se isključivo pri treniranju kako bi se povećala efektivna raznolikost ograničenog skupa i smanjilo prekomjerno prilagođavanje. Ključni zahtjev jest geometrijska konzistentnost: sve prostorne transformacije moraju se primijeniti identično na RGB kanal, dubinsku mapu i masku segmentacije istovremeno kako bi se spriječila prostorna neusklađenost modaliteta. Fotometrijske transformacije (promjena osvjetljenosti, kontrasta, zasićenosti) primjenjuju se isključivo na RGB kanal jer geometrijska informacija dubine nije ovisna o uvjetima osvjetljenja.

4. IMPLEMENTACIJA ALGORITMA

U ovom poglavlju detaljno je opisana implementacija cijeloga eksperimenta. Najprije je predstavljen podatkovni skup *BRANCH v2* i postupak njegovog prikupljanja i anotacije, nakon čega slijedi opis pretvorbe iz oblaka točaka u RGB-D format. Zatim su opisani razvojno okruženje, priprema podataka za treniranje te implementacijski detalji svih evaluiranih arhitektura. Poglavlje završava opisom konfiguracije treniranja, korištenih evaluacijskih metrika i posebnosti implementacije DFormer eksperimentalne grupe.

4.1. Opis podatkovnog skupa i preprocesiranje

Za potrebe ovog rada korišten je podatkovni skup *BRANCH v2* [11], koji predstavlja proširenu inačicu originalnog skupa podataka *BRANCH* [33], razvijenog u okviru istraživanja autonomne rezidbe stabala na Fakultetu elektrotehnike, računarstva i informacijskih tehnologija Osijek. Skup je javno dostupan na repozitoriju SRCE [34] i sadrži RGB-D snimke krušaka snimljenih u stvarnim uvjetima voćnjaka, kako prije tako i nakon rezidbe, pri čemu je svako stablo snimljeno s više različitih kutova gledišta radi cjelovite trodimenzionalne rekonstrukcije. Za potrebe ovog rada korišteni su isključivo podaci iz mape B/, odnosno snimke stabala prije rezidbe, budući da je cilj sustava prepoznavanje grana kandidata za rezidbu na neorezanom stablu.

Snimanje je provedeno kamerom *Asus Xtion Pro*, RGB-D senzorom koji kombinira standardnu kameru u boji s infracrvenim senzorom dubine temeljenim na tehnologiji strukturiranog svjetla. Za svaki snimljeni okvir dostupna je RGB slika u formatu *Portable Network Graphics* (PNG) te odgovarajuća dubinska mapa koja za svaki piksel kodira udaljenost od senzora do površine objekta u milimetrima. Unutarnji parametri kamere korišteni pri pretvorbi 3D oblaka točaka u 2D projekcije su žarišne duljine $F_X = F_Y = 570.34$ piksela te koordinate optičkog centra $C_X = 314.5$, $C_Y = 235.5$.

Sirove RGB-D snimke sadrže šum uzrokovan prisutnošću trave i tla u donjem dijelu kadra, što bi negativno utjecalo na kvalitetu segmentacije. Stoga su za sve eksperimente korišteni podaci iz mape *filtered_noGrass/*, koji su prošli automatski postupak uklanjanja trave razvijen u sklopu projekta [11]. Postupak se temelji na RANSAC (*Random Sample Consensus*) algoritmu za detekciju dominantne ravnine tla u oblaku točaka: algoritam iterativno procjenjuje parametre ravnine na nasumično odabranim podskupovima točaka i zadržava model koji opisuje najveći broj *inliera*, čime se robusno identificira ravnina tla čak i u prisutnosti *outliera*. Točke koje se nalaze unutar definiranog praga udaljenosti od detektirane ravnine uklanjaju se kao tlo i trava. Rezultantna mapa *filtered_noGrass/* sadrži tri relevantna podskupa podataka: RGB slike bez trave (*color/*.png*), dubinske mape bez trave (*depth/*.png*) te odgovarajuće oblake točaka u PLY formatu (*pc/*.ply*). PLY oblaci poslužili su kao osnova za postupak ručne i poluautomatske anotacije opisan u potpoglavlju 4.2, dok su RGB i dubinske slike korištene kao ulazni podaci za treniranje modela segmentacije nakon pretvorbe anotacija iz 3D u 2D prostor opisane u potpoglavlju 4.3.

4.2. Anotacija podataka

Anotacija podatkovnog skupa provedena je kroz četiri grupe koje se razlikuju po izvoru, metodi i razini nadzora. Definicija semantičkih klasa (pozadina, deblo, grane, potpora) opisana je u potpoglavlju 3.2, a ovdje se navode operativni detalji prikupljanja.

Grupa A sadrži 108 ručno anotiranih RGB-D slika 16 stabala iz različitih pogleda, koje je anotirao autor ovog rada u programu *CloudCompare*. Anotacije su visoke kvalitete jer su temeljito ručno provjerene i korigirane iz više kutova gledišta.

Grupa B sadrži 91 ručno anotiranu sliku 5 stabala iz različitih pogleda, koje je anotirao drugi istraživač istim postupkom. Kvaliteta anotacija analogna je Grupi A.

Grupa C sadrži 200 slika novih 13 stabala čije su anotacije inicijalno generirane automatski pomoću modela treniranog na grupama A i B, a potom ručno pregledane i ispravljene kako bi se osigurala kvaliteta usporediva s ručnom anotacijom. Ovaj pristup poluautomatske anotacije značajno je ubrzao proces u odnosu na potpuno ručno označavanje, pri čemu ručni pregled osigurava da greške modela ne uđu nekorisne u skup podataka.

Grupa D sadrži 258 slika novih 24 stabala anotiranih identičnim poluautomatskim postupkom kao grupa C, ali uz korištenje poboljšanog modela treniranog na svim prethodnim grupama (A, B i C). Poboljšani model generirao je inicijalne anotacije više kvalitete, što je smanjilo opseg potrebnih ručnih korekcija u usporedbi s grupom C.

Grupa C se koristi isključivo u skupu za treniranje zbog poluautomatskog porijekla anotacija manje kvalitete, dok skupovi za validaciju i testiranje sadrže isključivo ručno i bolje poluautomatsku anotiranu građu iz grupa A, B i D. Time se osigurava da evaluacija modela odražava stvarnu kvalitetu segmentacije na visokokvalitetnim referentnim oznakama (engl. *ground truth*), neovisno o bilo kojoj prethodnoj kvaliteti automatske predikcije. Ručna anotacija grupa A i B, te ručni pregled i korekcija grupa C i D, provedeni su u programu *CloudCompare*, besplatnom alatu otvorenog koda specijaliziranom za obradu, vizualizaciju i anotaciju trodimenzionalnih oblaka točaka.

Postupak anotacije za svaki PLY oblak odvijao se u tri koraka. U prvom koraku oblak se učitava u *CloudCompare* i vizualizira u 3D prikazu uz odgovarajuću RGB sliku kao referencu za određivanje semantičkih granica između klasa. Oblak se sistematski pregledava iz više kutova gledišta (prednje, bočne i gornje perspektive) kako bi se osigurala kompletnost anotacije u dijelovima koji bi bili okluzijom skriveni iz jedne perspektive. U drugom koraku korisnik ručno selektira skupove točaka poligonalnom selekcijom i dodjeljuje im numeričke oznake klasa kroz skalarno polje. Anotacija se provodi redoslijedom od geometrijski jednostavnijih prema složenijim klasama: deblo → potpora → grane. Ovaj redoslijed minimizira dvosmislenosti jer se nejasne granice između klasa rješavaju u kontekstu već označenih susjednih struktura. U trećem koraku provodi se vizualna provjera kompletnosti anotacije iz svih kutova i po potrebi korekcija graničnih regija, s posebnom pažnjom na mjesta grananja gdje deblo prelazi u primarne grane te na mjesta kontakta žica s granama gdje su vizualne granice klasa diskutabilno nejasne. Prosječno vrijeme ručne anotacije jednog oblaka točaka iznosilo je otprilike 5 minuta. Ukupan broj anotiranih uzoraka po grupama prikazan je u tablici 4.1.

Distribucija točaka po semantičkim klasama u anotiranom skupu pokazuje značajnu nerav-

Tab. 4.1: Pregled grupa podataka, metoda anotacije i njihove distribucije kroz skupove.

grupa	Metoda	Broj uzoraka	Koristi se u
A	Ručna anotacija	108	Trening / Validacija / Testiranje
B	Ručna anotacija	91	Trening / Validacija / Testiranje
C	Poluautomatska + ručni pregled	200	Samo treniranje
D	Poluautomatska + ručni pregled	258	Trening / Validacija / Testiranje
Ukupno		657	

nomjernost, s obzirom na to da su grane, a osobito potporne žice, izrazito tanke strukture u odnosu na dominantni volumen razgranate strukture stabla. Ova neravnomjernost dodatno je uzeta u obzir pri definiranju kombinirane funkcije gubitka opisane u potpoglavlju 4.7. Budući da su oblaci točaka prošli postupak uklanjanja tla i pozadinskih točaka opisan u potpoglavlju 4.1, u 3D prostoru anotacije prisutne su isključivo točke koje pripadaju stablu ili potpornim elementima. Klasa pozadine (klasa 0) stoga ne postoji u 3D anotaciji — svaka točka u oblaku klasificirana je kao deblo, grane ili potpora. Statistika anotiranih 3D točaka po klasama prikazana je u tablici 4.2, iz koje se vidi da u konačnom skupu podataka grane dominiraju s približno 74% udjela, dok deblo i potpora zauzimaju otprilike jednake dijelove (13% svaki).

Tab. 4.2: Broj i udio anotiranih 3D točaka po klasama u oblacima točaka nakon RANSAC filtriranja tla, za skupove korištene u eksperimentu 1 (399 uzoraka, 34 stabla) i eksperimentu 2 (657 uzoraka, 58 stabala). Klasa pozadine ne postoji u 3D anotaciji.

Klasa	Broj točaka (exp. 1)	Udio %	Broj točaka (exp. 2)	Udio %
Deblo (1)	4 195 764	13,78	6 894 695	13,18
Grane (2)	24 262 189	79,66	38 615 645	73,83
Potpora (3)	1 978 152	6,5	6 775 166	12,95

4.3. Pretvorba oblaka točaka u RGB-D format


Budući da su anotacije prikupljene u 3D prostoru oblaka točaka, a ciljne arhitekture za semantičku segmentaciju primaju 2D slike kao ulaz, neophodan je postupak koji anotacije iz 3D prostora prenosi u 2D prostor slike uz očuvanje prostorne korespondencije s RGB i dubinskim kanalima. U tu svrhu razvijena je skripta za pretvorbu koja za svaki anotirani PLY oblak prima tri ulaza: RGB sliku, dubinsku mapu i parametre intrinzične kalibracije kamere, te generira dva izlaza: četverokanalni RGB-D tenzor i odgovarajuću 2D masku segmentacije. Projekcija se temelji na modelu perspektivne kamere opisanom u potpoglavlju 3.2, s konkretnim parametrima kamere *Asus Xtion Pro* navedenim u potpoglavlju 4.1. Klasa pozadine (klasa 0) uvodi se implicitno tek u fazi projekcije 3D oblaka u 2D prostor slike. Svaki piksel 640×480 rešetke za koji ne postoji odgovarajuća 3D točka u oblaku, bilo zbog gubitka u *Z-buffer* koraku, bilo zbog padanja izvan vidnog polja, bilo zato što je originalna scena na tom mjestu bila prazna, ona dobiva oznaku pozadine. Kao posljedica, klasa pozadine dominira brojem piksela u 2D maskama, iako u izvornoj 3D anotaciji

uopće nije bila prisutna. Ovo objašnjava razliku između broja anotiranih 3D točaka u tablici 4.2 (ukupno 52,3 milijuna točaka) i broja *foreground* piksela nakon 2D projekcije (tablica 4.3, ukupno oko 43,4 milijuna piksela). Distribucija piksela po klasama u projiciranim 2D maskama prikazana je u tablici 4.3.

Tab. 4.3: Distribucija piksela po klasama u 2D maskama segmentacije nakon projekcije oblaka u prostor slike, za podskupove treniranja, validacije i testiranja Eksperimenta 2. Klasa pozadine dominira brojem piksela iako u 3D anotaciji nije bila prisutna.

Klasa	Treniranje (500 sl.)		Validacija (80 sl.)		Testiranje (77 sl.)	
	Piksela	%	Piksela	%	Piksela	%
0 – Pozadina	119 054 735	77,51	20 007 271	81,41	19 352 882	81,82
1 – Deblo	4 316 090	2,81	685 380	2,79	653 980	2,76
2 – Grane	25 604 381	16,67	3 728 117	15,17	3 100 067	13,11
3 – Potpora	4 624 794	3,01	155 232	0,63	547 471	2,31
Ukupno	153 600 000		24 576 000		23 654 400	

Iz prikazane distribucije vidljivo je da klasa pozadine dominira u svim skupovima (77–82% piksela), dok su *foreground* klase značajno manje zastupljene. Posebno je izražena neravnoteža klase potpore u validacijskom skupu (0,63%), što je posljedica slučajne raspodjele stabala po skupovima (neka stabla nemaju vidljivih potpornih elemenata). Omjer broja piksela pozadine i najrjeđe *foreground* klase iznosi do 29,7:1, što je uzeto u obzir pri odabiru kombinirane *CrossEntropyDiceLoss* funkcije gubitka opisane u potpoglavlju 4.7. Isto tako među *foreground* klasama, vidimo neravnomjernu distribuciju klasa. Klasa grane ima izrazito veću zastupljenost u podacima, za razliku od klasa deblo i potpora. Prikaz ulaznih podataka u mrežu se nalazi na slici 4.1



Sl. 4.1: Primjer ulaznih podataka u mrežu (Drvo 0025): (a) RGB slika, (b) dubinska mapa u paleti plasma (svjetliji tonovi označavaju veću blizinu senzora), (c) anotacijska maska klasa: deblo (crveno), grane (plavo) i potpora (zeleno).

U slučaju da više 3D točaka projicira na isti piksel, što se redovito događa na rubovima objekata i u regijama okluzije, primjenjuje se *Z-buffer* pristup: zadržava se oznaka točke koja je najbliža senzoru (manja vrijednost *Z* koordinate). Pikseli za koje ne postoji odgovarajuća 3D točka u oblaku označavaju se oznakom pozadine (klasa 0). Ovaj slučaj tipično se pojavljuje na rubovima slike i u regijama gdje je oblak točaka rijedak zbog okluzija ili ograničenja dometa senzora.

Skripta za svaki uzorak generira dvije sparene datoteke. Prva je četverokanalni *NumPy* tenzor pohranjen u NPY formatu (*.rgbd.npy, oblik [H, W, 4]) koji spaja normalizirane RGB kanale i normaliziranu dubinsku mapu u jedinstvenu strukturu pogodnu za izravno učitavanje u *PyTorch DataLoader*. Druga je maska segmentacije pohranjena kao PNG slika u sivim tonovima (*.mask.png, oblik [H, W]) s vrijednostima piksela 0-3 koji odgovaraju definiranim semantičkim klasama. Originalne dimenzije projekcije iznose 640×480 piksela, što odgovara stvarnoj rezoluciji senzora *Asus Xtion Pro*. Za treniranje svih modela slike su promijenjene na kvadratni format 640×640 piksela: za RGB i dubinski kanal primijenjena je bilinearna interpolacija koja čuva vizualne karakteristike, dok je za maske segmentacije primijenjena interpolacija najbližeg susjeda kako bi se spriječilo stvaranje nevažućih međuvrijednosti koje ne odgovaraju niti jednoj definiranoj klasi.

4.4. Razvojno okruženje

Eksperimenti su provedeni na tri različite hardverske konfiguracije ovisno o dostupnosti i zahtjevima pojedinog modela. Sve konfiguracije koristile su operacijski sustav *Ubuntu 22.04 LTS* s platformom *Compute Unified Device Architecture* (CUDA) za ubrzano računanje na grafičkim procesorskim jedinicama (engl. *Graphics Processing Unit*, GPU). Hardverske specifikacije korištene za pojedini eksperiment prikazane su u tablici 4.4.

Tab. 4.4: Hardverske specifikacije računala korištenih u eksperimentima.

Eksperiment	GPU	VRAM	CPU	RAM
Eksperiment 1,2,3	NVIDIA RTX 4060 Ti	8 GB	AMD Ryzen 5 7500X	32 GB
Eksperiment 1	NVIDIA RTX 3080 Ti	12 GB	AMD Ryzen 7 5800X	32 GB
Eksperiment 4	NVIDIA RTX 4080	16 GB	AMD Ryzen 9 7900X	64 GB

Cjelokupna implementacija provedena je u programskom jeziku *Python* uz korištenje dva odvojena *conda* okruženja zbog razlika u zavisnostima pojedinih arhitektura. *DFormer* modeli pokretani su u okruženju s *Python* 3.10 i CUDA 11.8, dok su preostali modeli (*ESANet*, *SegFormer* te arhitekture temeljene na *segmentation_models_pytorch*) pokretani u okruženju s *Python* 3.8 i CUDA 12.1. Kao temeljni okvir za duboko učenje korišten je *PyTorch* s CUDA podrškom za GPU akceleraciju. Za implementaciju standardnih enkoder-dekoder arhitektura korištena je biblioteka *segmentation_models_pytorch (smp)* koja pruža modularne komponente s prethodno treniranim baznim modelima. Za model *SegFormer* korišten je okvir *HuggingFace Transformers* s učitavanjem službenih prethodno treniranih težina, a za *ESANet* vlastita implementacija temeljena na *torchvision ResNet* modelima. Augmentacijske transformacije implementirane su korištenjem biblioteke *albumations* zbog njezine podrške za simultanu transformaciju višekanalnih ulaza različitih tipova, što je ključno za geometrijsku konzistentnost RGB, dubinskog i maskirnog kanala. Detaljan pregled verzija svih korištenih biblioteka za oba okruženja prikazan je u tablici 4.5.

Tab. 4.5: Verzije biblioteka korištenih u eksperimentima.

Biblioteka	DFormer / DFormer v2	ESANet / SegFormer / smp
Python	3.10.20	3.8.20
PyTorch	2.1.2+cu118	2.1.0+cu121
torchvision	0.16.2+cu118	0.16.0+cu121
CUDA	11.8	12.1
segmentation_models_pytorch	-	0.3.3
transformers (HuggingFace)	-	4.46.3
albumentations	-	1.4.18
numpy	1.26.4	1.24.4
opencv-python	4.13.0	4.10.0
scipy	1.15.3	1.10.1
CloudCompare	2.6.1	

4.5. Priprema podataka za treniranje

Podjela podataka provedena je na razini stabala u omjeru 70:15:15 (treniranje, validacija, testiranje) uz fiksni *random seed* 42 za ponovljivost, kako je konceptualno opisano u potpoglavlju 3.5. Konkretna raspodjela za svaku eksperimentalnu fazu prikazana je u tablici 4.6.

Tab. 4.6: Raspodjela broja uzoraka po skupovima za eksperimente 1 i 2.

Skup	Broj uzoraka (exp. 1)	Broj uzoraka (exp. 2)
Treniranje	333	500
Validacija	31	80
Testiranje	35	77
Ukupno	399	657

Nakon definiranja podjele podataka implementirana je normalizacija prema formulama opisanim u potpoglavlju 3.5. RGB kanali normalizirani su *ImageNet* statistikama ($\mu = [0.485, 0.456, 0.406]$, $\sigma = [0.229, 0.224, 0.225]$), a dubinska mapa rezanjem na $d_{\max} = 4.0$ m i skaliranjem na $[0, 1]$. Uz normalizaciju, implementirane su i augmentacijske transformacije korištenjem *albumentations* biblioteke s *additional_targets* mehanizmom koji osigurava istovremenu primjenu geometrijskih transformacija na RGB kanal, dubinsku mapu i masku segmentacije. Augmentacija se primjenjuje isključivo pri treniranju dok se pri validaciji i testiranju primjenjuje samo normalizacija. Primijenjene tehnike prikazane su u tablici 4.7.

4.6. Implementacija arhitektura

Svi modeli implementirani su s proširenjem ulaznog konvolucijskog sloja na odgovarajući broj kanala prema strategiji opisanoj u potpoglavlju 3.3. U nastavku su navedeni konkretni implementacijski detalji za svaku arhitekturu.

Modeli *U-Net* s *ResNet-34* i *EfficientNet-B4* su implementirani korištenjem *segmentation_models_pytorch* biblioteke. Ulazni konvolucijski sloj proširen je s 3 na 4 kanala (Eks. 1/2) ili 6

Tab. 4.7: Transformacije augmentacije podataka i pripadajući parametri.

Transformacija	Parametri	Primjenjuje se na
Horizontalno zrcaljenje	$p = 0.5$	RGB + dubina + maska
Nasumična rotacija	$\pm 10^\circ$	RGB + dubina + maska
Promjena osvjetljenosti		Samo RGB
Promjena kontrasta		Samo RGB
Promjena zasićenosti		Samo RGB

kanala (Eks. 3) uz inicijalizaciju dodatnih kanala prosjekom RGB težina. Odabrana stopa učenja iznosi: 1×10^{-4} .

Na istoj su biblioteci implementirani i modeli *DeepLabV3* s *ResNet-50* te *DeepLabV3+* s *MobileNetV2*. Njihov ASPP modul konfiguriran je s proširenim konvolucijama stopa proširenja 6, 12 i 18, dok je ulaz proširen identično *U-Net* modelima. Odabrana stopa učenja iznosi 1×10^{-4} .

Model *SegFormer-B1* je učitao iz prethodno treniranih *HuggingFace* težina (*nvidia/segformer-b1-finetuned-ade-512-512*). Ulazni projekcijski sloj prvog *patch embedding* bloka je modificiran za višekanalni ulaz, gdje se originalna 3 kanala inicijaliziraju se kopiranjem prethodno treniranih težina, a dodatni kanali inicijaliziraju se *Kaiming* normalnom inicijalizacijom. Izlazne vrijednosti dimenzija $[B, K, H/4, W/4]$ uzorkuju se bilinearnom interpolacijom na dimenzije ulaza. Odabrana stopa učenja iznosi 6×10^{-5} .

Slično prethodnima, model *MA-Net* s *ResNeXt-50* implementiran je korištenjem *segmentation_models_pytorch* s baznim modelom *ResNeXt-50_32x4d*. Ulaz je proširen identično ostalim *smp* modelima, a odabrana stopa učenja iznosi 1×10^{-4} .

Za razliku od navedenih, model *Pix2Pix* implementiran je na temelju originalne arhitekture [32]. Generator je *U-Net* s 8 enkoder i 8 dekoder blokova koji prima višekanalni RGB-D ulaz i na izlazu daje nenormalizirane vrijednosti za $K = 4$ klase. Diskriminator je *PatchGAN* koji klasificira 70×70 zakrpe. Testirane su dvije varijante: *pix2pix_gan* s punim *adversarial* treniranjem i *pix2pix_gen* samo s generatorom. Odabrana stopa učenja iznosi 2×10^{-4} , $\beta_1 = 0.5$ za *Adam* optimizator.

Posljednji model ove eksperimentalne skupine, *ESANet* vlastita je implementacija temeljena na *torchvision ResNet* modelima. RGB enkoder temelji se na *ResNet-34*, a enkoder za dubinsku mapu na *ResNet-18*, oba prethodno trenirana na *ImageNet* skupu. Inicijalizacija dubinskog enkodera provodi se prema izrazu:

$$W_{depth}^{conv1} = \frac{1}{3} \sum_{c=1}^3 W_{RGB}^{conv1,(c)} \quad (4-1)$$

SE-fuzijski moduli su konfigurirani na svakoj od četiri razine hijerarhije (64, 128, 256, 512 kanala). *Bottleneck* razina obrađuje spojene značajke proširenim konvolucijama s faktorima 2 i 4. *ESANet* je evaluiran samo u Eksperimentima 1 i 2 jer arhitektura pretpostavlja jednokanalni dubinski ulaz pa ga nema smisla implementirati na trokanalnom dubinskom ulazu. Odabrana stopa učenja iznosi 1×10^{-4} .

Naposljetku, HHA enkodiranje (Eksperiment 3) provedeno je korištenjem implementacije *charlesCXXK/Depth2HHA-python* uz parametre kamere $F_X = F_Y = 570.34$, $C_X = 314.5$, $C_Y = 235.5$. Dubinska mapa proslijeđena je u metrima. Izlaz je trokanalnog *uint8* niza oblika $[H, W, 3]$ pohranjen kao `*_hha.npy`. Ulazni tenzor za Eksperiment 3 oblika je $[6, H, W] = \text{RGB}(3) + \text{HHA}(3)$. *ESANet* nije evaluiran u Eksperimentu 3 jer pretpostavlja jednokanalni dubinski ulaz.

4.7. Konfiguracija treniranja

U nastavku su opisane odabrana funkcija gubitka, korišteni optimizator sa strategijom prilagodbe stope učenja, pregled zajedničkih i model-specifičnih hiperparametara te način praćenja eksperimenata i pohrane najboljih modela.

Zbog značajne neravnomjernosti distribucije klasa korištena je kombinirana *CrossEntropyDiceLoss* koja zbraja gubitak unakrsne entropije i *Dice* gubitak:

$$\mathcal{L} = \mathcal{L}_{CE} + \mathcal{L}_{Dice} \quad (4-2)$$

Funkcija gubitka unakrsne entropije optimizira vjerojatnosnu raspodjelu predviđanja na razini piksela:

$$\mathcal{L}_{CE} = -\frac{1}{N} \sum_{i=1}^N \sum_{k=0}^{K-1} y_{ik} \log \hat{p}_{ik} \quad (4-3)$$

Dice gubitak izravno optimizira mjeru preklapanja između predikcije i referentne oznake, što je posebno korisno za klase s malim udjelom piksela poput tankih grana:

$$\mathcal{L}_{Dice} = 1 - \frac{2 \sum_i y_i \hat{p}_i}{\sum_i y_i + \sum_i \hat{p}_i} \quad (4-4)$$

Kombinacija ovih dviju funkcija gubitaka empirijski je robusnija od same unakrsne entropije pri neravnomjernim raspodjelama klasa [2].

Svi modeli prve grupe trenirani su *Adam* optimizatorom s regularizacijom težina $\lambda = 1 \times 10^{-5}$. Raspored stope učenja implementiran je kao kosinusni pad (*CosineAnnealingLR*) s minimalnom stopom $\eta_{\min} = 1 \times 10^{-6}$:

$$\eta(t) = \eta_{\min} + \frac{1}{2}(\eta_0 - \eta_{\min}) \left(1 + \cos \frac{\pi t}{T_{\max}} \right) \quad (4-5)$$

gdje t označava tekuću epohu, η_0 početnu stopu učenja, a $T_{\max}$ ukupan broj epoha.

Radi transparentnosti i ponovljivosti eksperimenata, u nastavku su navedeni svi ključni hiperparametri korišteni pri treniranju modela prve eksperimentalne grupe. Hiperparametri su podijeljeni u dvije skupine: zajedničke postavke koje vrijede za sve modele (tablica 4.8) i model-specifične stope učenja određene prema prirodi svake arhitekture (tablica 4.9).

Zajednički hiperparametri odabrani su tako da osiguraju usporedivost rezultata kroz sve modele. Veličina serije uzoraka postavljena je na 4 kao maksimalna vrijednost koja stane u dostupnu memoriju grafičkog procesora najzahtjevnijih modela pri rezoluciji 640×640 . Maksimalan broj epoha postavljen je na 100 uz mehanizam ranog zaustavljanja (engl. *early stopping*) s toleranci-

Tab. 4.8: Pregled hiperparametara korištenih pri treniranju svih modela prve eksperimentalne grupe.

Hiperparametar	Vrijednost
Veličina <i>batch</i> -a	4
Broj epoha	100
<i>Early stopping patience</i>	15
Dimenzije ulaznih slika	640×640
<i>Number of workers</i>	2
<i>Random seed</i>	42

jom od 15 epoha bez poboljšanja validacijskog mIoU-a, što u praksi znači da se treniranje najčešće prekida prije dostignutog maksimuma. Fiksna inicijalna vrijednost (*random seed*) 42 osigurava ponovljivost inicijalizacije težina, redoslijeda uzoraka u serijama i primjene augmentacija.

Tab. 4.9: Pregled modela, arhitektura i stope učenja korištenih pri treniranju u prvoj eksperimentalnoj grupi.

Model	Bazni model	Stopa učenja	Ulazni kanali (Eks. 1 i 2 / Eks. 3)
<i>U-Net</i>	<i>ResNet-34</i>	1×10^{-4}	4 / 6
<i>U-Net</i>	<i>EfficientNet-B4</i>	1×10^{-4}	4 / 6
<i>DeepLabV3</i>	<i>ResNet-50</i>	1×10^{-4}	4 / 6
<i>DeepLabV3+</i>	<i>MobileNetV2</i>	1×10^{-4}	4 / 6
<i>SegFormer</i>	B1	6×10^{-5}	4 / 6
<i>MA-Net</i>	<i>ResNeXt-50_32$\times$4d</i>	1×10^{-4}	4 / 6
<i>Pix2Pix</i>	<i>U-Net</i> gen.	2×10^{-4}	4 / —
<i>ESANet</i>	<i>ResNet-34 + ResNet-18</i>	1×10^{-4}	4 / —

Većina modela koristi standardnu stopu učenja 1×10^{-4} koja se pokazala kao stabilna vrijednost za konvolucijske arhitekture s *Adam* optimizatorom. *SegFormer-B1* koristi nižu stopu 6×10^{-5} prema preporuci autora izvornog rada [30] za fino podešavanje prethodno treniranih *transformer* enkodera, budući da veće stope kod *transformerskih* arhitektura mogu narušiti već naučene reprezentacije. *Pix2Pix* koristi višu stopu 2×10^{-4} i *Adam* parametar $\beta_1 = 0,5$ prema izvornoj konfiguraciji [32], što je uobičajena postavka za suparničko treniranje. Stupac ulaznih kanala pokazuje razlike prema eksperimentalnoj fazi: Eksperimenti 1 i 2 koriste četverokanalni ulaz RGB+dubina, dok Eksperiment 3 koristi šesterokanalni ulaz RGB+HHA. *Pix2Pix* i *ESANet* nisu evaluirani na HHA ulazu zbog arhitekturnih ograničenja detaljno opisanih u potpoglavlju 5.3.

Tijekom cijelog procesa treniranja praćene su i pohranjivane sve relevantne vrijednosti radi kasnije analize i mogućnosti reprodukcije rezultata. Svaki eksperiment bilježi vrijednosti po epohama u datoteku zapisa u formatu vrijednosti odvojenih zarezima (engl. *Comma-Separated Values*, CSV): gubitke treniranja i validacije, trenutnu stopu učenja i sve evaluacijske metrike na validacijskom skupu. *Checkpoint* s najboljim mIoU na validacijskom skupu čuva se u .pth datoteci koja sadrži stanje modela, stanje optimizatora i postignutu mIoU vrijednost. Prijevremeno zaustavljanje aktivira se nakon 15 uzastopnih epoha bez poboljšanja validacijskog mIoU, čime se smanjuje rizik

od prekomjernog prilagođavanja i nepotrebnog računalnog troška.

Navedene vrijednosti hiperparametara nisu odabrane proizvoljno, nego su rezultat niza pripremih pokretanja provedenih tijekom razvoja *pipeline*-a. Ispitane su alternativne stope učenja, konfiguracije funkcije gubitka i postavke augmentacije, no nijedna od njih nije nadmašila ovdje prikazanu konfiguraciju na validacijskom skupu. Kako ta pokretanja nisu provedena pod jednakim i sustavno bilježenim uvjetima, njihovi rezultati ne prikazuju se kao mjerodavni, već se navode isključivo kao obrazloženje odabira konačne konfiguracije za prvu eksperimentalnu grupu.

4.8. Evaluacijske metrike

Za evaluaciju modela korišten je skup komplementarnih metrika koje zajedno daju cjelovitu sliku kvalitete segmentacije.

Srednji IoU (engl. *mean Intersection over Union*, mIoU) primarni je pokazatelj kvalitete segmentacije. Za svaku klasu c , IoU se računa kao omjer presjeka i unije predviđanja i referentne oznake na razini piksela:

$$\text{IoU}_c = \frac{TP_c}{TP_c + FP_c + FN_c} \quad (4-6)$$

mIoU je aritmetička sredina IoU vrijednosti za klase debla, grana i potpore – klasa pozadine isključena je iz izračuna jer zbog dominantnog udjela piksela maskira stvarne razlike između modela:

$$\text{mIoU} = \frac{1}{3} \sum_{c=1}^3 \text{IoU}_c \quad (4-7)$$

Granična F1-mjera (engl. *Boundary F1*, BF1) mjeri preciznost segmentacije na granicama objekata. Rubni pikseli izlučuju se erozijom, a približno podudaranje (engl. *fuzzy matching*) između predviđenih i stvarnih rubnih piksela provodi se dilacijom uz jezgru od $\theta = 2$ piksela. Vrijednost mBF1 označava aritmetičku sredinu BF1 vrijednosti po klasama debla, grana i potpore, analogno načinu na koji se mIoU računa iz IoU vrijednosti. Granična F1-mjera posebno je relevantna za tanke strukture poput grana, gdje je preciznost granica kritična za primjenu u robotskoj rezidbi.

Odziv grana (engl. *Branch Recall*) mjeri odziv isključivo za klasu grana (klasa 2):

$$\text{Odziv}_{\text{grane}} = \frac{TP_{\text{grane}}}{TP_{\text{grane}} + FN_{\text{grane}}} \quad (4-8)$$

U kontekstu autonomne rezidbe ova metrika od posebne je važnosti jer nedetektirana grana direktno utječe na kvalitetu plana rezidbe – propuštena grana znači propuštenu rezidbu.

Ukupna točnost piksela (engl. *Overall Accuracy*, OA) mjeri udio ispravno klasificiranih piksela od svih piksela:

$$\text{OA} = \frac{\sum_c TP_c}{\sum_c (TP_c + FP_c)} \quad (4-9)$$

Točnost piksela klasa objekta (engl. *Pixel Accuracy foreground*, PA fg) racuna se jednako kao OA, ali isključivo nad pikselima klasa debila, grana i potpore, dok se pozadinska klasa izostavlja iz brojnika i nazivnika. Oznaka fg (engl. *foreground*) u nastavku rada označava upravo taj podskup klasa, odnosno sve klase osim pozadine. Budući da pozadina čini 77–82 % piksela u tipičnoj sceni, PA fg daje reprezentativniji uvid u uspješnost modela na klasama od interesa nego OA.

Frekvencijski ponderirani IoU (FWIoU) varijanta je mIoU metrike koja uzima u obzir stvarnu raspodjelu klasa u skupu podataka ponderiranjem IoU vrijednosti svake klase proporcionalno njezinom udjelu u ukupnom broju piksela:

$$\text{FWIoU} = \frac{1}{\sum_{c=0}^{K-1} t_c} \sum_{c=0}^{K-1} t_c \cdot \text{IoU}_c \quad (4-10)$$

gdje $t_c = TP_c + FN_c$ označava ukupan broj stvarnih piksela klase c . Za razliku od mIoU koji sve klase tretira ravnopravno, FWIoU daje veći doprinos klasama s većim brojem piksela (u ovom slučaju pozadini i granama), čime je osjetljiviji na štetu performansi na dominantnim klasama. Primijenjen kao dopuna mIoU-u, FWIoU omogućuje razlikovanje modela koji ostvaruju visoki mIoU poboljšanjem točnosti na rijetkim klasama na štetu čestih od onih modela koji daju dosljedno dobre rezultate na svim klasama. Analogno prethodnome, FWIoU fg označava frekvencijski ponderirani IoU izračunat samo nad klasama objekta, bez pozadine, čime se uklanja utjecaj dominantne pozadinske klase na ponderiranje.

4.9. DFormer eksperimentalna grupa – posebnosti implementacije

DFormer koristi vlastiti *framework* za učitavanje podataka koji očekuje drugačiju strukturu od formata korištenog u prvoj eksperimentalnoj grupi. Konverzija je provedena skriptom koja iz sparenih *_rgb.d.npy i *_mask.png datoteka generira tri odvojene mape:

- RGB/ – RGB kanali pretvoreni iz *float* [0, 1] u *uint8* [0, 255] i pohranjeni kao PNG datoteke,
- Depth/ dubinski kanal pohranjen kao 16-bitna PNG slika u milimetrima množenjem s 1000. Ovaj format standardan je za RGB-D skupove poput *NYUDepth v2* i *SUNRGB-D* na kojima su *DFormer* modeli prethodno trenirani, čime se osigurava kompatibilnost normalizacijskih statistika,
- Label/ maska segmentacije izravno kopirana iz *_mask.png (vrijednosti 0–3).

Uz svaku mapu generiraju se tekstualne datoteke train.txt, val.txt i test.txt s popisom uzoraka koji odgovaraju podjeli opisanoj u potpoglavlju 4.5. Nad ovako pripremljenim podacima trenirano je šest varijanti DFormer arhitekture, po tri veličine (Small, Base i Large) iz svake od dviju objavljenih generacija — DFormer v1 kao izvorne arhitekture i DFormer v2 kao njezine kasnije nadogradnje. Specifični hiperparametri za svaku varijantu prikazani su u tablici 4.10.

DFormer eksperimenti razlikuju se od prve eksperimentalne grupe u nekoliko ključnih aspekata koji odražavaju preporučene postavke iz originalnih radova [9, 10]: Za treniranje se koristi

Tab. 4.10: Konfiguracijski parametri i prethodno trenirani modeli za *DFormer* varijante.

Varijanta	Bazni model	Prethodno trenirani	Batch	Epohe	drop_path
<i>DFormer-Small</i>	<i>DFormer-Small</i>	<code>DFormer_Small.pth.tar</code>	4	200	0.05
<i>DFormer-Base</i>	<i>DFormer-Base</i>	<code>DFormer_Base.pth.tar</code>	4	200	0.10
<i>DFormer-Large</i>	<i>DFormer-Large</i>	<code>DFormer_Large.pth.tar</code>	4	200	0.10
<i>DFormer v2-Small</i>	<i>DFormerv2_S</i>	<code>DFormerv2_Small_pretrained.pth</code>	4	200	0.25
<i>DFormer v2-Base</i>	<i>DFormerv2_B</i>	<code>DFormerv2_Base_pretrained.pth</code>	4	200	0.25
<i>DFormer v2-Large</i>	<i>DFormerv2_L</i>	<code>DFormerv2_Large_pretrained.pth</code>	4	200	0.25

optimizator *AdamW* s $\beta = (0.9, 0.999)$ i $\lambda = 0.01$. *AdamW* je preporučen za transformer arhitekture jer *decoupled weight decay* ispravno regulira sve parametre neovisno o gradijentu, za razliku od standardnog *Adam* optimizatora. Za raspored stope učenja se koristi *WarmUpPolyLR* s linearnim zagrijavanjem ($T_{warmup} = 5$ epoha za *Base* i *Large*, $T_{warmup} = 10$ za *Small*) praćenim polinomijalnim padom:

$$\eta(t) = \eta_0 \cdot \left(1 - \frac{t}{T_{total}}\right)^p \quad (4-11)$$

gdje je $p = 0.9$ ili 0.95 ovisno o varijanti. Korištena je funkcija gubitka *CrossEntropyLoss* s *label smoothing* = 0.1 umjesto *CrossEntropyDiceLoss*. *Label smoothing* smanjuje prekomjerno prilagođavanje na malom skupu podataka penaliziranjem previše sigurnih predikcija. Dodatno, tijekom treniranja primijenjena je višerazmjerna augmentacija pri čemu se za *Base* i *Large* varijante koristila skala $[0.5, 0.75, 1.0, 1.25, 1.5]$, a za *Small* varijantu $[0.75, 1.0, 1.25]$. Pri evaluaciji korišteno je višerazmjerno testiranje (engl. *Multi-Scale Test*, MST) pri kojemu se ulazne slike obrađuju s više skala $[0.5, 0.75, 1.0, 1.25, 1.5]$ uz horizontalno zrcaljenje, što tipično poboljšava mIoU za 1–2 postotna boda u odnosu na evaluaciju s jednom skalom. Za učinkovitije korištenje memorije i ubrzavanja procesa treniranja korištena je automatska miješana preciznost (engl. *Automatic Mixed Precision*, AMP), implementirana pomoću `torch.cuda.amp.GradScaler` s `float16`. Ovaj pristup smanjuje memorijski zahtjev i ubrzava treniranje, uz zadržavanje odgovarajuće numeričke preciznosti. Posebna prilagodba napravljena je za model *DFormer-Small*, kod kojeg su zbog izražene neravnomjernosti zastupljenosti klasa u manjem skupu podataka eksperimentalno uvedene težine $w = [5.73, 1.00, 6.09]$ koje odgovaraju inverznoj frekvenciji klasa debla, grana i potpore.

Radi jasnoće interpretacije rezultata prikazanih u sljedećem poglavlju, u tablici 4.11 sažete su ključne razlike u konfiguraciji treniranja i evaluacije između dviju eksperimentalnih grupa. Grupa 1 obuhvaća sve modele s prethodno treniranim baznim modelima na skupu *ImageNet* (Eksperimenti 1, 2 i 3), dok grupa 2 obuhvaća modele s RGB-D specifično prethodno treniranim baznim modelima iz obitelji *DFormer* (Eksperiment 4).

Iz tablice je vidljivo da se dvije grupe razlikuju u znatno više dimenzija od samog prethodnog treniranja. Grupa 2 koristi drugačiji optimizator, drugačiji raspored stope učenja, drugačiju regularizaciju gubitka, kao i višerazmjerno treniranje i evaluaciju te miješanu preciznost. Ove razlike u konfiguraciji treniranja trebaju se uzeti u obzir pri interpretaciji rezultata Eksperimenta 4: povećanje točnosti segmentacije koji će biti prikazani ne mogu se pripisati isključivo prethodnom

Tab. 4.11: *Usporedba karakteristika i konfiguracije treniranja između grupe 1 i grupe 2.*

Karakteristika	grupa 1 (<i>ImageNet</i>)	grupa 2 (<i>DFormer</i>)
Bazni model	<i>ImageNet</i> (RGB)	<i>NYU Depth v2 / SUN RGB-D</i>
Optimizator	<i>Adam</i>	<i>AdamW</i>
Raspored stope učenja	<i>CosineAnnealingLR</i>	<i>WarmUpPolyLR</i>
Funkcija gubitka	CE + <i>Dice</i>	CE + <i>label smoothing</i>
Višerazmjerno treniranje	Ne	Da [0,5–1,5]
MST evaluacija	Ne	Da
AMP	Ne	Da
Okvir	<i>PyTorch</i> + <i>smp</i>	<i>DFormer</i> okvir
Ulazni format	[<i>C, H, W</i>] . <i>numpy</i>	RGB. <i>png</i> + Depth. <i>png</i> (16-bit)
Dekoder	Specifičan za model	HAM (<i>embed_dim</i> = 512)

treniranju na RGB-D podacima, već predstavljaju kombinirani doprinos prethodnog treniranja i optimizacijskog protokola. Detaljna analiza ovog pitanja dana je u potpoglavlju 5.5.

5. EKSPERIMENTALNA EVALUACIJA I REZULTATI

Eksperimentalna evaluacija provedena je kroz četiri komplementarne faze koje sustavno raščlanjuju doprinos triju ortogonalnih dizajnerskih odluka na ukupnu kvalitetu semantičke segmentacije grana stabala: (1) veličine i raznolikosti podatkovnog skupa za fino podešavanje (Eksperiment 1 naspram Eksperimenta 2), (2) strategije enkodiranja modaliteta dubine na ulazu mreže (Eksperiment 2 naspram Eksperimenta 3), i (3) paradigme prethodnog treniranja baznog modela na *ImageNet* (RGB) podacima naspram RGB-D specifičnog prethodnog treniranja (Eksperimenti 1–3 naspram Eksperimenta 4).

U nastavku se rezultati analiziraju redom – prvo unutar svake eksperimentalne faze (unutark eksperimentalna analiza, gdje se uspoređuju arhitekture pod istim uvjetima), a zatim između faza (međueksperimentalna analiza, gdje se izolira doprinos pojedinog faktora držeći ostale što je moguće konstantnima).

5.1. Eksperiment 1

Prvi eksperiment predstavlja *baseline* konfiguraciju: osam arhitektura (*U-Net* s dva bazna modela, *DeepLabV3*, *DeepLabV3+*, *SegFormer-B1*, *MA-Net*, te dvije varijante *Pix2Pix*) treniranih na 399 uzoraka iz grupa A, B i C uz augmentaciju te ranu fuziju jednokanalne dubine kao četvrtog ulaznog kanala. Ovaj eksperiment služi kao referentna točka prema kojoj se mjeri doprinos kasnijih intervencija (više podataka, HHA enkodiranje, prethodno treniranje na RGB-D podacima). Rezultati eksperimenta 1 su prikazani u tablici 5.1.

Tab. 5.1: Rezultati Eksperimenta 1 (399 uzoraka, jednokanalna dubina, vrijednosti u postocima).

Model	OA	mIoU	mBF1	Odziv grana	IoU pozadina	IoU deblo	IoU grane	IoU potpora	Odziv pozadina	Odziv deblo	Odziv grane	Odziv potpora
<i>U-Net ResNet-34</i>	96,95	54,80	78,77	91,43	97,55	61,42	82,85	20,14	98,80	73,68	91,43	21,89
<i>U-Net EfficientNet-B4</i>	97,37	57,22	84,48	93,33	97,98	66,20	84,89	20,58	98,80	78,68	93,33	21,57
<i>DeepLabV3 ResNet-50</i>	96,65	55,03	83,89	92,95	97,10	63,00	81,67	20,41	97,94	75,66	92,95	21,64
<i>SegFormer-B1</i>	96,80	56,16	83,05	91,76	97,22	66,24	82,18	20,06	98,13	81,84	91,76	21,71
<i>MA-Net ResNeXt50</i>	97,18	56,60	82,81	91,41	97,71	65,74	83,90	20,14	98,77	81,38	91,41	21,11
<i>DeepLabV3+ MobileNetV2</i>	96,04	52,76	81,58	87,32	96,41	60,21	78,30	19,76	98,19	76,18	87,32	21,12
<i>Pix2Pix GAN</i>	96,39	51,36	77,05	86,31	97,13	57,48	79,28	17,31	98,94	78,47	86,31	18,12
<i>Pix2Pix Gen</i>	96,95	53,62	63,51	92,53	97,62	58,59	82,82	19,46	98,56	70,52	92,53	20,53

Svi evaluirani modeli postižu ukupnu točnost piksela u rasponu 96,04–97,37%, što na prvi pogled izgleda kao odličan rezultat. Međutim, ova je metrika u ovom kontekstu gotovo beskorisna kao pokazatelj kvalitete jer njome dominira klasa pozadine, koja čini znatnu većinu piksela u tipičnoj sceni voćnjaka. Model koji bi sve piksele klasificirao kao pozadinu vjerojatno bi postigao OA u rasponu 70–80% (ovisno o stvarnoj distribuciji klasa), pa razlika između najboljeg (97,37%) i najlošijeg (96,04%) modela od samo 1,33 postotna boda prikriva značajne razlike u stvarnoj korisnosti modela, koje otkrivaju druge metrike.

Znatno informativniji uvid daje srednji presjek nad unijom (mIoU). Raspon mIoU vrijednosti kreće se od 51,36% do 57,22%, pri čemu najbolji rezultat ostvaruje *U-Net* s *EfficientNet-B4* baznim modelom, a najlošiji *Pix2Pix* GAN. Razlika od 5,86 postotnih bodova između najboljeg i najlošijeg modela vidljiva je i praktično relevantna, premda razlike u OA sugeriraju da su svi modeli približno usporedivi.

Dodatni uvid u kvalitetu segmentacije pruža granična F1-mjera (mBF1), te je posebno značajna u zadatku segmentacije tankih struktura poput grana, gdje je precizno lociranje ruba često važnije od ukupne pokrivenosti. Analiza po ovoj metrici otkriva prvi obrazac koji odstupa od poretka po mIoU: *Pix2Pix* Gen postiže mBF1 od samo 63,51%, što je znatno niže od svih ostalih modela, čije se vrijednosti kreću u rasponu 76–85%, unatoč solidnom mIoU od 53,62%, čime zauzima šesto mjesto. Ovaj obrazac upućuje na to da *Pix2Pix* Gen dobro identificira koji pikseli pripadaju kojoj klasi (o čemu svjedoči visok IoU), ali proizvodi maske s nedovoljno oštro definiranim granicama. Takvo je ponašanje konzistentno s poznatim svojstvom generativnih modela treniranih bez *adversarial* komponente: bez diskriminatora koji kažnjava nerealne uzorke, generator optimiziran isključivo na pikselnoj razini proizvodi usrednjene izlaze na granicama gdje je referentna oznaka dvosmislena.

Uz navedene metrike, važan pokazatelj je i odziv po klasi (engl. *class recall*), koji mjeri koliki je udio stvarnih piksela pojedine klase model uspio detektirati. Odziv grana kreće se u rasponu 86,31–93,33%, što pokazuje da svi modeli detektiraju veliku većinu piksela grana. *Pix2Pix* Gen ovdje postiže drugi najviši odziv od 92,53%, gotovo identičan najboljim modelima, unatoč slaboj mBF1-mjeri. Ovaj kontrast dodatno potvrđuje prethodnu konstataciju: model je sklon segmentirati dominantnu klasu grana, ali ne poštuje precizne granice objekata.

Analiza po pojedinim klasama otkriva izražene razlike u težini zadatka koji svaka klasa predstavlja. Pozadina, kao dominantna klasa, očekivano je najbolje riješena, s IoU vrijednostima u rasponu 96,04–97,98% i dosljedno najvišim odzivom (97,94–98,94%) kod svih modela. Klasa debla druga je po točnosti, s IoU vrijednostima od 57,48% do 66,24% i odzivom od 70,52% do 81,84%. Ovdje se ističu *SegFormer-B1* (IoU 66,24%, odziv 81,84%) i *U-Net s EfficientNet-B4* (IoU 66,20%, odziv 78,68%), koji postižu praktički identičan IoU, ali *SegFormer* ostvaruje znatno viši odziv, što je konzistentno s očekivanjima od *transformer* arhitekture na geometrijski kompaktnim klasama. Klasa grana, koja je od najvećeg praktičnog interesa za primjenu u robotskom rezidbanju, pokazuje raspon IoU vrijednosti od 78,30% do 84,89% te odziva od 87,32% do 93,33%. Najbolji rezultat na ovoj klasi ostvaruje *U-Net s EfficientNet-B4* osnovnom mrežom (IoU 84,89%, odziv 93,33%), dok najslabije rezultate dosljedno pokazuje *DeepLabV3+ s MobileNetV2* (IoU 78,30%, odziv 87,32%). Klasa potpore, koja obuhvaća stupove i žice, najslabija je klasa za sve modele, s velikom razlikom u odnosu na ostale — IoU vrijednosti kreću se u rasponu 17,31–20,58%, što je tri do pet puta niže od IoU debla. Ono što je posebno indikativno jest da su razlike među modelima minimalne (raspon od samo 3,27 postotnih bodova), što upućuje na to da problem nije arhitektonske prirode, već fundamentalno metodološki: rana fuzija jednokanalne dubine ne pruža dovoljno eksplicitnu geometrijsku informaciju za razlučivanje potpornih žica i stupova od grana.

5.2. Eksperiment 2

Drugi eksperiment proširuje podatkovni skup s 399 na 657 uzoraka dodavanjem grupe D, koja u Eksperimentu 1 nije bila dostupna. Budući da grupa D sudjeluje i u validaciji i u testiranju, testni skup Eksperimenta 2 (77 slika) nije identičan testnom skupu Eksperimenta 1 (35 slika). Usporedba između tih dvaju eksperimenata stoga mjeri zajednički učinak povećanja skupa za treniranje

i promjene testnog skupa, što treba uzeti u obzir pri tumačenju razlike. Uz identičnu arhitekturalnu i augmentacijsku konfiguraciju kao Eksperiment 1, s jednom dodatnom arhitekturom: *ESANet*, jedina arhitektura u ovoj grupi dizajnirana od temelja za RGB-D ulaz s paralelnim enkoder granama (potpoglavlje 3.3.3). Iz tablice 5.2 razaznaju se tri glavna nalaza.

Tab. 5.2: Rezultati Eksperimenta 2 (657 uzoraka, jednokanalna dubina, vrijednosti u postocima).

Model	OA	PA_fg	FWIoU	FWIoU_fg	mIoU	mBF1	Odziv grana	IoU pozadina	IoU deblo	IoU grane	IoU potpora	Odziv deblo	Odziv potpora
<i>U-Net ResNet-34</i>	98,56	93,62	97,34	88,12	68,75	81,96	93,97	99,36	76,20	89,81	40,24	90,21	43,74
<i>U-Net EfficientNet-B4</i>	98,70	94,01	97,58	88,88	69,76	84,72	94,82	99,41	76,66	90,46	42,17	89,91	43,86
<i>DeepLabV3 ResNet-50</i>	98,31	93,45	96,85	87,33	69,44	86,05	93,72	98,83	78,03	88,19	42,10	90,63	43,92
<i>SegFormer-B1</i>	98,38	93,54	96,95	87,76	70,21	85,61	93,67	98,88	78,56	88,62	43,44	90,86	45,62
<i>MA-Net ResNeXt50</i>	98,68	93,96	97,56	88,89	69,35	82,24	93,84	99,49	76,81	90,67	40,59	91,89	43,99
<i>DeepLabV3+ MobileNetV2</i>	98,09	92,35	96,45	85,58	66,48	83,54	92,75	98,75	74,97	86,83	37,65	89,43	39,86
<i>ESANet ResNet-34</i>	98,66	94,54	97,47	89,43	71,41	89,51	95,30	99,06	81,25	90,31	42,66	90,58	44,02

Prvo, svih šest *ImageNet*-inicijaliziranih modela s dubinskim ulazom ostvarilo je značajno poboljšanje u odnosu na Eksperiment 1, uz prosječan porast od približno 13 postotnih bodova mIoU preko svih zajedničkih modela. Nalaz je konzistentan kroz cijelu obitelj arhitektura, što sugerira da je količina podataka za fino podešavanje bila dominantno ograničavajući čimbenik u prethodnom eksperimentu. Drugo, unutar *ImageNet* obitelji razlike između arhitektura postale su znatno manje izražene nego u Eksperimentu 1, najbolji *SegFormer-B1* (70,21 %) i najslabiji *DeepLabV3+ MobileNetV2* (66,48 %) razdvaja svega 3,73 boda mIoU. Time je potvrđen princip prema kojemu podatkovni skup za fino podešavanje ima veći utjecaj od arhitekturalnog izbora u specijaliziranim domenama s ograničenim podacima. Treće, *ESANet ResNet-34* kao arhitektura specifično dizajnirana za RGB-D ulaz postiže najviši mIoU od 71,41 %, nadmašujući najbolji *ImageNet* model za +1,20 boda. Ova razlika, iako manja od skoka između eksperimenata, konzistentna je kroz sve klase i kroz mBF1 metriku, gdje *ESANet* ostvaruje 89,51 % naspram maksimalnih 86,05 % *ImageNet* modela. Klasa potpore doživljava najveće apsolutno poboljšanje (+21,51 boda), njezin IoU se praktički udvostručuje, čemu pridonosi i činjenica da se broj piksela te klase više nego udvostručio. Klasa deblo bilježi drugo najveće poboljšanje (+13,49 boda), dok klasa grana, koja je već u Eksperimentu 1 bila relativno dobro riješena, bilježi umjereniji ali još znatan dobitak (+6,82 boda). Prosjek IoU po klasama prikazan je u tablici 5.3.

Tab. 5.3: Učinak proširenja skupa na IoU po klasama (prosjek 6 zajedničkih modela).

Klasa	Pros. IoU Eks. 1	Pros. IoU Eks. 2	Δ IoU
Pozadina	97,45	99,12	+1,67
Deblo	63,39	76,87	+13,49
Grane	82,31	89,13	+6,82
Potpura	19,69	41,20	+21,51

ESANet postiže najbolji mIoU (71,41 %) u ovom eksperimentu, nadmašujući i najbolji model iz Eksperimenta 1 za +14,19 boda. *ESANet* nadmašuje čak i *U-Net EfficientNet-B4* unutar Eksperimenta 2 (69,76%) za +1,65 boda, unatoč tome što koristi samo *ResNet-34* za RGB granu. Ovo je ključan nalaz: arhitekturalni dizajn koji eksplicitno modelira RGB-D modalitet kroz paralelne enkoder grane i SE-fuzijske module nadmašuje veći, prethodno trenirani RGB bazni model kojem


je dubina naknadno dodana kao ulazni kanal, čak i kada oba koriste isključivo prethodno trenirane RGB bazne modele. Razlika je posebno izražena na klasi debla (*ESANet* IoU debla 81,25%, najviši od svih modela u oba eksperimenta) i mBF1 (89,51%, s velikom marginom od +3,46 boda iznad drugog). Ova razlika, iako kvantitativno manja od skoka između eksperimenata, znanstveno je značajna iz dva razloga. Prvo, poboljšanje je konzistentno kroz sve *foreground* klase, s najvećim relativnim skokom kod klase debla (81,25 % IoU) i mBF1 kvalitete granica (89,51 %). Drugo, ovaj rezultat pokazuje da geometrijski svjesna arhitektura može dodatno poboljšati kvalitetu segmentacije čak i s *ImageNet* inicijalizacijom, ali je taj efekt ograničen granicama koje postavlja prethodno treniranje na RGB podacima. Iza *ESANet*-a, razlike između preostalih šest modela su relativno male (mIoU 66,48–70,21%, raspon od 3,73 boda). *SegFormer-B1* zauzima drugo mjesto (70,21%) s daleko najvišim IoU debla (78,56%) i odzivom debla (90,86%) među *ImageNet* modelima, ponovno potvrđujući da *transformer* arhitektura posebno dobro modelira debla. *DeepLabV3+ MobileNetV2* ostaje najlošiji (66,48%), konzistentno s Eksperimentom 1.

5.2.1. Kvalitativna usporedba *U-Net*-a i *ESANet*-a


Za izravnu vizualnu procjenu poboljšanja, na slikama 5.1 i 5.2 prikazane su predikcije dvaju reprezentativnih modela iz drugog eksperimenta na šest identičnih testnih primjera najbržeg modela *U-Net ResNet-34* (mIoU 68,75 %) i najtočnijeg modela *ESANet ResNet-34* (mIoU 71,41 %). Time se omogućuje identifikacija tipova pogrešaka koje karakteriziraju svaku konfiguraciju.

Predikcija *U-Net*-a na slici 5.1b reproducira globalnu prostornu strukturu triju klasa, ali detaljnija analiza otkriva sustavne slabosti karakteristične za *ImageNet*-inicijalizirane arhitekture bez posebne obrade tankih linearnih struktura. Prvo, klasa potpore u petom retku djelomično se gubi, gdje model umjesto potpornih žica predviđa granu ili pozadinu. Drugo, tanke krajnje grančice pojavljuju se fragmentirane ili u potpunosti propuštene. Treće, u istom retku predikcija sadrži lažno pozitivne linearne strukture klasificirane kao potpora koje u referentnoj oznaci (slika 5.1a) ne postoje. Pikselni prikaz na slici 5.1c kvantitativno potvrđuje ova zapažanja: rasprostranjena plava područja (FN) uz rubove grana ukazuju na sustavnu nepotpunost segmentacije, dok crvena područja (FP) na spojevima grana i debla pokazuju semantičko preklapanje između klasa.


Vizualna usporedba *ESANet*-a s prethodno prikazanim *U-Net*-om pokazuje napredak u segmentacijskoj kvaliteti. Predikcija na slici 5.2b reproducira detaljniju strukturu grana s manjim brojem prekida u tankim krajnjim područjima, a rubovi debla zaokruženi su i geometrijski dosljedniji referentnoj oznaci prikazanoj na slici 5.2a. Pikselni prikaz na slici 5.2c pokazuje veću zastupljenost zelenih (TP) područja u odnosu na *U-Net*, uz smanjenje plavih (FN) regija na granicama grana. Ovaj napredak konzistentan je s kvantitativnim nalazom iz tablice 5.2, gdje *ESANet* nadmašuje sve ostale modele za +1,20 do +4,93 postotnih bodova mIoU-a. Ključni izazovi segmentacije klase potpore i finih rubnih struktura grana ostaju prisutni i u *ESANet*-u, što motivira daljnji korak prema prethodnom treniranju na RGB-D podacima koji je središnji predmet Eksperimenta 4.



(a) Referentna oznaka




(b) Predikcija modela




(c) Prikaz uspješnosti na razini piksela za klasu grana


Sl. 5.1: Kvalitativni rezultati modela U-Net ResNet-34 (Eksperiment 2, mIoU 68,75 %): (a) referentna oznaka: deblo (crveno), grane (plavo), potpora (zeleno), (b) predikcija modela u istoj shemi boja, (c) prikaz uspješnosti na razini piksela za klasu grana: TP (zeleno), FP (crveno), FN (plavo).



(a) Referentna oznaka



(b) Predikcija modela



(c) Prikaz uspješnosti na razini piksela za klasu grana

Sl. 5.2: Kvalitativni rezultati modela ESANet ResNet-34 (Eksperiment 2, mIoU 71,41 %): (a) referentna oznaka: deblo (crveno), grane (plavo), potpora (zeleno), (b) predikcija modela u istoj shemi boja, (c) prikaz uspješnosti na razini piksela za klasu grana: TP (zeleno), FP (crveno), FN (plavo).

5.2.2. Brzina inferencije

Tablica 5.4 prikazuje izmjerena vremena obrade po slici za sve modele prve eksperimentalne grupe, mjereno na testnom skupu od 77 slika uz uključenu automatsku mijesšanu preciznost (AMP).

Tab. 5.4: Brzina inferencije modela prve eksperimentalne grupe po slici (GPU: CUDA, 77 slika testnog skupa, 10 slika zagrijavanja, AMP uključen).

Model	Pros. (ms)	Std. (ms)	Min (ms)	Maks (ms)	FPS
<i>DeepLabV3+ MobileNetV2</i>	6,72	0,27	6,37	7,51	148,86
<i>U-Net ResNet-34</i>	11,67	0,40	10,95	13,25	85,71
<i>DeepLabV3 ResNet-50</i>	15,50	0,53	14,59	16,62	64,52
<i>SegFormer-B1</i>	15,83	0,47	14,92	16,87	63,17
<i>ESANet ResNet-34</i>	16,89	0,50	15,92	17,73	59,20
<i>U-Net EfficientNet-B4</i>	23,13	0,66	21,55	24,30	43,23
<i>MA-Net ResNeXt-50</i>	33,57	0,99	31,45	35,19	29,79

Unutar prve eksperimentalne grupe postoje značajne razlike u brzini inferencije – raspon od 6,72 ms (*DeepLabV3+ MobileNetV2*) do 33,57 ms (*MA-Net ResNeXt-50*) predstavlja razliku od 5 puta. *DeepLabV3+ s MobileNetV2* daleko je najbrži model (148,86 FPS), konzistentno s njegovom laganom arhitekturom namijenjenom mobilnim platformama, no uz najlošiji mIoU u grupi (66,48%). Ovo ga čini neprivačnim izborom za primjenu gdje je točnost prioritet. *ESANet* (16,89 ms, 59,20 FPS) postiže povoljan omjer između točnosti (71,41% mIoU, najbolji u grupi) i brzine – jedino je arhitekturno dizajniran za RGB-D ulaz, a istovremeno nije značajno sporiji od jednostavnijih modela poput *DeepLabV3* i *SegFormer-a*. *MA-Net s ResNeXt-50* je najsporiji (33,57 ms, 29,79 FPS), no i dalje unutar granica prihvatljivih za primjenu koja ne zahtijeva obradu u stvarnom vremenu, kakva je statična analiza stabla prije planiranja putanje rezača.

5.3. Eksperiment 3

Treći eksperiment zadržava 657 uzoraka i identičnu arhitekturnu konfiguraciju kao Eksperiment 2 (bez *ESANet-a*), ali zamjenjuje jednokanalnu dubinu trokanalnim HHA enkodiranjem (potpoglavlja 3.3.2 i 4.6), formirajući šesterokanalni ulaz RGB(3)+HHA(3). *ESANet* je isključen jer arhitektura pretpostavlja jednokanalni dubinski ulaz za svoju zasebnu dubinsku enkoder granu, pa nije direktno kompatibilna s trokanalnim HHA ulazom. Pokušaj evaluacije *ESANet-a* na HHA ulazu rezultirao je degeneriranim rezultatima (mIoU $\approx$ 0,32%).

Tab. 5.5: Rezultati Eksperimenta 3 (657 uzoraka, augmentacija, HHA enkodiranje, vrijednosti u postocima).

Model	OA	PA_fg	FWIoU	FWIoU_fg	mIoU	mBF1	Odziv grana	IoU pozadina	IoU deblo	IoU grane	IoU potpora
<i>U-Net ResNet-34</i>	98,28	92,60	96,84	86,26	66,59	81,68	92,47	99,13	74,59	87,87	37,32
<i>U-Net EfficientNet-B4</i>	98,42	93,12	97,10	87,20	68,32	82,02	93,27	99,19	75,10	88,68	41,17
<i>DeepLabV3 ResNet-50</i>	98,08	92,27	96,41	85,74	67,42	84,36	92,77	98,65	75,94	86,70	39,60
<i>SegFormer-B1</i>	98,06	92,56	96,41	85,80	67,72	84,22	92,70	98,63	76,02	86,49	40,66
<i>DeepLabV3+ MobileNetV2</i>	97,76	90,79	95,85	83,58	64,76	81,64	91,31	98,44	73,42	84,74	36,11

Uspoređujući rezultate Eksperimenta 3 vidljive u tablici 5.5 s Eksperimentom 2, odmah je uočljivo da HHA enkodiranje nije donijelo očekivano poboljšanje – štoviše, sve arhitekture bilježe blagu, ali konzistentnu degradaciju mIoU u rasponu od 1,5 do 2,5 boda. Raspon mIoU vrijednosti (64,76–68,32%) ostaje usporediv s Eksperimentom 2, no cijela distribucija pomaknuta je prema dolje.

Ukupna točnost piksela (OA) ostaje visoka (97,76–98,42%), no kao i u prethodnim eksperimentima, ova metrika je dominirana klasom pozadine i nije informativan pokazatelj stvarne kvalitete segmentacije. Klasa pozadine (IoU pozadine: 98,44–99,19%) ostaje stabilno visoka kroz sve modele, konzistentno s prethodnim eksperimentima. Klasa debla (IoU debla: 73,42–76,02%) pokazuje umjerenu degradaciju u odnosu na Eksperiment 2. *SegFormer-B1* zadržava prednost na ovoj klasi (76,02%), što je konzistentno s nalazima iz prethodnih eksperimenata gdje *transformer* arhitektura dosljedno dobro modelira geometrijski konzistentne, kompaktne strukture. Klasa grana (IoU grana: 84,74–88,68%) ostaje relativno stabilna, s *U-Net EfficientNet-B4* kao najboljim modelom (88,68%). Odziv grana (91,31–93,27%) konzistentan je s vrijednostima iz Eksperimenta 2, što sugerira da HHA enkodiranje ne narušava sposobnost detekcije grana. Klasa potpore (IoU potpore: 36,11–41,17%) ostaje najproblematičnija klasa, no što je posebno znakovito – HHA enkodiranje nije poboljšalo detekciju potpore u odnosu na Eksperiment 2 (42,66% za *ESANet*, koji ovdje nije dostupan za usporedbu). Detaljnija analiza ovog negativnog rezultata dana je u potpoglavlju 5.3.1.

Unutar Eksperimenta 3, poredak po mIoU je: *U-Net EfficientNet-B4* (68,32%) > *SegFormer-B1* (67,72%) > *DeepLabV3 ResNet-50* (67,42%) > *U-Net ResNet-34* (66,59%) > *DeepLabV3+ MobileNetV2* (64,76%). Ovaj poredak je gotovo identičan onome iz Eksperimenta 2 – degradacija je "uniformna" u smislu da ne mijenja koji je model relativno bolji, samo snižava apsolutnu razinu svih.

5.3.1. Direktna usporedba HHA naspram jednokanalne dubine

Rezultat eksperimenta 3 je iznenađujući i protivan inicijalnoj hipotezi da će drugačije enkodiranje dubine poboljšati rezultat. HHA enkodiranje konzistentno smanjuje mIoU za svih pet modela, u rasponu od -1,44 boda do -2,49 boda, s prosjekom od -1,97 boda što je vidljivo u tablici 5.6. Standardna devijacija je niska (0,39), što znači da je degradacija konzistentna kroz različite arhitekture.

Tab. 5.6: HHA naspram jednokanalne dubine, po modelu (mIoU u %).

Model	mIoU jednokanalna dubina (Eks. 2)	mIoU HHA (Eks. 3)	Δ mIoU
<i>U-Net ResNet-34</i>	68,75	66,59	-2,16
<i>U-Net EfficientNet-B4</i>	69,76	68,32	-1,44
<i>DeepLabV3 ResNet-50</i>	69,44	67,42	-2,02
<i>SegFormer-B1</i>	70,21	67,72	-2,49
<i>DeepLabV3+ MobileNetV2</i>	66,48	64,76	-1,72
Prosjek	68,93	66,96	-1,97

Prosjek IoU po klasama testiranih 5 modela vidljiv je u tablici 5.7. Degradacija je najizraženija na klasama potpore (-2,38) i grana (-1,99) upravo klasama koje je HHA enkodiranje

Tab. 5.7: HHA naspram jednokanalne dubine, IoU po klasama (prosjeak 5 modela).

Klasa	IoU jednokanalna dubina (Eks. 2)	IoU HHA (Eks. 3)	Δ IoU
Pozadina	99,07	98,83	-0,24
Deblo	76,45	75,01	-1,44
Grane	88,89	86,90	-1,99
Potpورا	41,35	38,97	-2,38

trebalo poboljšati prema originalnoj motivaciji. Klasa pozadine bilježi minimalnu degradaciju (-0,24), a deblo umjerenu (-1,44).

Nekoliko mogućih objašnjenja za ovaj kontraintuitivni nalaz:

1. Pouzdanost ravnine tla nakon RANSAC uklanjanja trave. HHA kanal visina iznad tla (h_{ground}) zahtijeva procjenu ravnine tla. U *BRANCH* v2 skupu, RANSAC algoritam za uklanjanje trave (potpoglavlje 3.5) već je uklonio velik dio točaka tla *prije* nego se HHA enkodiranje provodi na preostaloj dubinskoj mapi. Posljedica: ravnina tla procijenjena u HHA *pipeline-u* temelji se na rjeđem, potencijalno nereprezentativnom skupu točaka, što unosi sustavnu pogrešku u h_{ground} kanal.
2. Informacijski kompromis pri promjeni dimenzionalnosti ulaza. Prijelaz s 4 na 6 ulaznih kanala uvodi dodatne parametre u prvom konvolucijskom sloju. Ovi dodatni parametri zahtijevaju više podataka za stabilnu konvergenciju. Pri 657 uzoraka, moguće je da je model u Eksperimentu 3 blago “podtreniran” u odnosu na povećani kapacitet.
3. HHA kao gubitnička transformacija. HHA je determinirana transformacija jednokanalne dubine, teoretski, mreža s dovoljnim kapacitetom mogla bi implicitno naučiti ekvivalentnu reprezentaciju iz jednokanalne dubine. Ako su eksplicitne HHA značajke računate s greškom (točka 1), mogu uvesti šum bez kompenzacijske dobiti.
4. Fundamentalna razlika u ciljanom zadatku segmentacije. Prednost HHA enkodiranja validirana je u [5] na scenariju u kojem mreža razlikuje *cilindrične drvene strukture* (deblo, grane, grančice) od *ravnih lisnatih površina* (lišće) – upravo onaj geometrijski kontrast koji HHA enkodiranje eksplicitno kodira kroz kanal kuta normale s gravitacijom $\alpha_{gravity}$: cilindrične površine imaju karakteristično varijabilan kut normale, dok su lisne površine gotovo ravne. Kako i sami autori tog rada navode, drvenaste regije poput debbla i grana imaju cilindrični oblik za razliku od listova čije su površine ravne, a HHA enkodiranje upravo tu geometrijsku razliku implicitno kodira [5].

U *BRANCH* v2 skupu [34] situacija je kvalitativno drugačija: stabla su snimljena bez lišća (zimski rezidba), pa klasa lišća uopće ne postoji. Segmentacijski zadatak ne zahtijeva razlikovanje cilindričnih grana od ravnih listova, već razlikovanje drvenih cilindričnih grana od betonskih cilindričnih potpornih stupova i metalnih žica, struktura koje su geometrijski gotovo identične u HHA prostoru. Prednost HHA enkodiranja koja se manifestira u u tom sce-

nariju scenariju [5] (cilindar naspram ravnina) ovdje strukturalno ne postoji, što objašnjava izostanak poboljšanja neovisno o veličini skupova podataka ili gustoći dubinskih mapa.

Premda je apsolutna degradacija mala (~ 2 mIoU %), konzistentnost smjera kroz svih pet arhitektura (standardna devijacija samo 0,39) sugerira da je ovo stvaran, ponovljiv učinak za ovu konkretnu kombinaciju *dataset/pipeline*. Posebno je relevantna interpretacija iz točke 4: HHA enkodiranje donosi korist upravo u zadacima koji zahtijevaju razlikovanje cilindričnih od ravnih površina (drvo vs. lišće), ali ne i u zadacima poput ovog gdje su sve ciljne klase geometrijski slične (cilindrično drvo naspram cilindrični metalni stupovi). Ovo je vrijedan negativan rezultat koji upozorava da se nalazi o prednostima HHA enkodiranja iz literature ne smiju nekritički prenositi na domene s drugačijim geometrijskim profilom klasa.

5.4. Eksperiment 4


Četvrti eksperiment predstavlja kvalitativni skok u eksperimentalnom dizajnu: evaluirane su *DFormer v1 (Small/Base/Large)* i *DFormer v2 (Small/Base/Large)* arhitekture čiji su bazni modeli prethodno trenirani od temelja na RGB-D podacima (*NYU Depth v2*, *SUN RGB-D*) kroz *masked autoencoder* zadatak (potpoglavlje 3.3.4), zatim fino podešeni i evaluirani na 657 uzoraka skupa *BRANCH v2* uz specifičnu konfiguraciju treniranja opisanu u potpoglavlju 4.9. Kvantitativni rezultati svih šest evaluiranih varijanti prikazani su u tablici 5.8.

Tab. 5.8: Rezultati *DFormer* eksperimenta (vrijednosti u %).

Model	OA	PA_fg	FWIoU	FWIoU_fg	mIoU	mBF1	Odziv grana	IoU pozadina	IoU deblo	IoU grane	IoU potpora	BF1 deblo	BF1 grane	BF1 potpora
<i>DFormer-Small</i>	98,19	93,53	96,55	87,50	87,20	96,08	94,40	98,57	80,68	88,04	92,89	93,09	97,99	97,15
<i>DFormer-Base</i>	98,25	93,78	96,67	87,95	87,67	96,28	94,30	98,61	81,69	88,45	92,88	93,65	98,12	97,07
<i>DFormer-Large</i>	98,24	93,91	96,65	87,90	87,66	96,29	94,58	98,59	81,53	88,36	93,09	93,56	98,11	97,21
<i>DFormerv2-Small</i>	97,94	92,25	96,11	85,48	84,75	94,81	92,27	98,48	77,89	86,33	90,04	91,68	97,24	95,50
<i>DFormerv2-Base</i>	98,01	93,11	96,25	85,98	85,21	95,05	93,74	98,54	78,18	86,88	90,57	91,77	97,41	95,98
<i>DFormerv2-Large</i>	98,06	93,17	96,35	86,27	85,45	95,12	93,65	98,59	78,62	87,19	90,56	92,01	97,44	95,90

Iz tablice 5.8 razaznaju se dva ključna nalaza. Prvo, sve tri varijante iz *DFormer v1* obitelji postižu mIoU u uskom rasponu od 87,20 % do 87,67 %, čime nadmašuju sve modele iz prethodnih eksperimenata za više od 16 mIoU bodova. Najbolji rezultat od 87,67 % mIoU postiže *DFormer-Base*, koji istovremeno ostvaruje najveću IoU vrijednost za klasu deblo (81,69 %) uz visokih 92,88 % za klasu potpore, klasu koja je u svim prethodnim eksperimentima bila kritični nedostatak. Drugo, kompletna *DFormer v2* obitelj dosljedno zaostaje za *v1* obitelji: najbolja varijanta *DFormerv2-Large* postiže 85,45 % mIoU, što je 2,21 boda niže od najbolje *v1* varijante. Ovaj negativan transfer arhitekturnih poboljšanja detaljno je analiziran kasnije u potpoglavlju 5.4. Kvalitativna ilustracija segmentacije *DFormer-Base* modela na šest reprezentativnih testnih primjera prikazana je na slici 5.3.

Vizualna usporedba između predikcije (slika 5.3b) i referentne oznake (slika 5.3a) potvrđuje kvantitativni nalaz iz tablice 5.8: model dosljedno reproducira prostornu strukturu sve tri klase kroz šest različitih scena iz podatkovnog skupa. Prevladavajuća zelena područja na slici 5.3c pokazuju da najveći dio piksela klase grana model klasificira ispravno, dok su crvena (FP) i plava (FN) područja ograničena i lokalizirana. Uočljive pogreške koncentrirane su na tri tipa mjesta:



(a) Referentna oznaka

(b) Predikcija modela

(c) Prikaz uspješnosti na razini piksela za klasu grana

Sl. 5.3: Kvalitativni rezultati modela *DFormer-Base* na testnom skupu: (a) referentna oznaka (deblo (crveno), grane (plavo), potpora (zeleno)), (b) predikcija modela u istoj shemi boja, (c) pikselni prikaz uspješnosti za klasu grana (TP (zeleno), FP (crveno), FN (plavo)).

tanke krajnje grančice gdje je referentna oznaka rijetka i geometrijski nesigurna, područja kontakta grana i debla gdje je granica između klasa inherentno zamućena te rijetki primjeri lažno pozitivnih potpornih žica uočljivi u petom retku slike, gdje model predviđa dodatne linearne strukture klasificirane kao potpora iako u referentnoj oznaci ne postoje. Posljednji tip pogreške ilustrira jedno od preostalih ograničenja modela.

Unutar *DFormer v1* obitelji, razlike između *Small* (87,20%), *Base* (87,67%) i *Large* (87,66%) su izuzetno male, *Base* i *Large* su praktički identični (razlika 0,01 boda), dok *Small* zaostaje za samo 0,47 boda unatoč znatno manjem broju parametara i kraćem treniranju. Ovo je klasičan obrazac zakona opadajućih prinosa pri skaliranju modela: kada bazni model već posjeduje snažnu geometrijski svjesnu reprezentaciju iz prethodnog treniranja na RGB-D podacima, dodatni parametri ne donose značajnu korist na skupu od 657 uzoraka. Praktična implikacija: *DFormer-Base* predstavlja optimalan odabir za primjenu u robotskoj rezidbi: postiže statistički najbolji mIoU uz manji memorijski i računalni otisak od *Large* varijante.

Najupečatljiviji nalaz ovog eksperimenta jest da *DFormer v2*, unatoč arhitekturnim poboljšanjima opisanim u potpoglavlju 2.3 [10], dosljedno zaostaje za *DFormer v1* za sve tri usporedive veličine što je vidljivo u tablici 5.9 Razlika je iznimno konzistentna između +2,21 i +2,46

Tab. 5.9: *DFormer v1* naspram *v2*, po veličini (mIoU u %).

Veličina	DFormer v1	DFormerv2	Δ (v1 - v2)
<i>Small</i>	87,20	84,75	+2,45
<i>Base</i>	87,67	85,21	+2,46
<i>Large</i>	87,66	85,45	+2,21

bodova, s prosjekom +2,37 i standardnom devijacijom samo 0,13. Ova konzistentnost kroz tri veličine sugerira sustavnu karakteristiku kako se *v2* arhitektura odnosi prema ovoj specifičnoj domeni. U tablici 5.10 je vidljiv mIoU po klasama *Base* modela *DFormera* i *DFormerv2*.

Tab. 5.10: *DFormer-Base* naspram *DFormerv2-B*, IoU po klasama (%).

Klasa	DFormer-Base	DFormerv2-Base	Δ
Pozadina	98,61	98,54	+0,07
Deblo	81,69	78,18	+3,51
Grane	88,45	86,88	+1,57
Potpورا	92,88	90,57	+2,31

Ovaj kontraintuitivan rezultat može se pripisati nekoliko čimbenika, premda bez dodatnih eksperimenata nije moguće s pouzdanošću utvrditi koji je od njih dominantan. Prva mogućnost odnosi se na strategiju prethodnog treniranja: *DFormer v2* koristi veći omjer maskiranja tijekom *self-supervised* treniranja [10], što model tjera na učenje globalnijih reprezentacija korisnih u scenama s velikim kontinuiranim okluzijama. Scene voćnjaka, međutim, karakterizira drugačija struktura okluzije: fine isprepletene grane umjesto velikih kontinuiranih regija, pa naučene reprezentacije možda nisu optimalno prilagođene ovoj domeni.

Dodatni uzrok može se tražiti u većem broju naučenih parametara koje uvodi *differential cross-attention* mehanizam [10]. Ovakvi dodatni parametri tipično zahtijevaju više podataka za pouzdanu kalibraciju, a s dostupnih 657 uzoraka moguće je da mehanizam ne konvergira u korisnu konfiguraciju. Sličnu ulogu mogao je odigrati i složeniji *multi-scale fusion head* druge generacije, čije adaptivne težine predstavljaju dodatni stupanj slobode koji na malom skupu podataka može otežati generalizaciju u odnosu na jednostavniji HAM dekodir prve generacije.

Konačno, valja uzeti u obzir i domenu na kojoj je *DFormer v2* razvijen i validiran. Poboljšanja druge generacije primarno su osmišljena za segmentaciju gusto opremljenih unutarnjih prostora, što je kvalitativno drugačiji problem od segmentacije tanke i složene strukture voćnjaka s manjim brojem semantičkih klasa. Dobiveni rezultat u skladu je s općenitim opažanjem da novije verzije arhitektura ne moraju automatski nadmašivati prethodne kada se primjenjuju na specijaliziranu domenu izvan njihovog razvojnog konteksta.

5.4.1. Brzina inferencije

U tablici 5.11 prikazani su prosjeci višestrukih mjerenja vremena *inferencije* po slici za sve varijante *DFormer* obitelji, dobiveni prolaskom kroz kompletan testni skup od 77 slika uz 10 slika zagrijavanja i uključeno miješano precizno računanje (AMP). Unutar *DFormer v1* obitelji brzina

Tab. 5.11: Brzina inferencije *DFormer* modela po slici (GPU: CUDA, 77 slika testnog skupa, 10 slika zagrijavanja, AMP uključen; za *DFormer v2-S* i *DFormer v2-B* prikazani su prosjeci višestrukih mjerenja).

Model	Pros. (ms)	Std. (ms)	Min (ms)	Maks (ms)	FPS
<i>DFormer-Small</i>	12,15	0,35	11,74	13,20	82,28
<i>DFormer-Base</i>	20,11	0,80	19,36	22,52	49,73
<i>DFormer-Large</i>	27,28	1,11	25,73	30,33	36,65
<i>DFormer v2-Small</i>	45,99	2,62	43,12	54,60	21,75
<i>DFormer v2-Base</i>	71,66	2,43	67,26	80,74	13,96
<i>DFormer v2-Large</i>	89,81	2,16	86,02	96,94	11,13


inferencije raste očekivano s veličinom modela – *DFormer-Small* (12,15 ms, 82,28 FPS), *DFormer-Base* (20,11 ms, 49,73 FPS) i *DFormer-Large* (27,28 ms, 36,65 FPS), pri čemu su sve tri varijante prihvatljivo brze za primjenu u robotskoj rezidbi. Posebno je zanimljivo da *DFormer-Small* postiže brzinu usporedivu s modelima prve eksperimentalne grupe (12,15 ms naspram 11,67 ms za *U-Net ResNet-34*), uz znatno višu točnost (87,20% naspram 70% mIoU). Nasuprot tome, *DFormer v2* modeli su drastično sporiji od v1 verzije. *DFormer v2-Small* troši prosječno 45,99 ms po slici, što je gotovo četiri puta više od *DFormer-Small*-a uz nižu točnost (84,75% naspram 87,20% mIoU). *DFormer v2-Base* troši prosječno 71,66 ms, više od tri puta sporije od *DFormer-Base*-a, a *DFormer v2-Large* je najsporiji model u cijelom istraživanju (89,81 ms, 11,13 FPS). Ova kombinacija niže točnosti i znatno veće računalne zahtjevnosti dodatno učvršćuje zaključak iznesen ranije u potpoglavlju 5.4 da *DFormer v2* nije konkurentan *DFormer v1*-u za ovu primjenu.

Sveukupno, *DFormer-Base* ostaje najbolji model i s perspektive omjera točnosti i brzine:

49,73 FPS dovoljan je za primjenu u robotskoj rezidbi gdje sustav obrađuje statične snimke stabla prije planiranja putanje rezača, a postiže najveći mIoU (87,67%) od svih evaluiranih konfiguracija.

5.4.2. Detaljna analiza pogrešaka DFormer-Base modela

Kako bi se detaljnije analizirale pogreške *DFormer-Base* modela, koji se u prethodnim odjeljcima izdvojio kao najbolji evaluirani model, u ovom potpoglavlju provodi se kvantitativna analiza pogrešaka putem matrice zabune te kvalitativna analiza najgoreg predikcijskog primjera na testnom skupu.




Sl. 5.4: Matrica zabune modela *DFormer-Base* na testnom skupu (77 slika), prikazana kao postotak piksela u retku (retci normalizirani na 100 %). Dijagonalni elementi predstavljaju točno klasificirane piksele, izvandijagonalni elementi predstavljaju sistemske pogreške klasifikacije.

Središnji empirijski nalaz koji podupire tvrdnju o dobiti od prethodnog treniranja na RGB-D podacima vidljiv je u posljednjem retku matrice na slici 5.4: klasa potpore, koja je u svim eksperimentima prve grupe bila najproblematičnija klasa s IoU vrijednostima u rasponu 17–43 %, sada je klasificirana s točnošću od 96,46 %. Preostala zabuna s klasom grana (2,61 %) minimalna je i geometrijski očekivana, javlja se u područjima gdje potporne žice prolaze u istoj vertikalnoj ravnini s tankim granama, čime u 2D projekciji dijele identičan tanki linearni profil.

Najistaknutija preostala sistemska pogreška vidljiva je u drugom retku matrice: 8,88 % piksela referentne klase debela model klasificira kao grane. Ovo nije neočekivano jer prijelaz s debela na primarne grane u krošnji kruške čini geometrijski kontinuum bez oštre granice čak i pri ručnoj anotaciji, gdje je moguće da dva anotatora različito označe zonu grananja. Preostale zabune su manje značajne: deblo se u 1,40 % slučajeva miješa s pozadinom, što se događa na dubinskim rubovima gdje senzor *Asus Xtion Pro* proizvodi nepouzdana mjerenja, a grane se u 3,34 % slučajeva

miješaju s pozadinom, uglavnom na krajnjim grančicama subpikselske širine. Klasa pozadine s 99,19 % točno klasificiranih piksela potvrđuje da model nije riješio manjinske klase žrtvovanjem točnosti na dominantnoj klasi, što je česta patologija u domenama s ekstremno neravnomjernom raspodjelom klasa.

Kako bi se izbjegao dojam pristrane selekcije rezultata kroz prikazivanje samo tipičnih predikcijskih primjera, na slici 5.5 prikazan je testni primjer s najnižim izmjerenim mIoU-om u testnom skupu *DFormer-Base* modela.



Sl. 5.5: Testni primjer s najnižim izmjerenim mIoU za *DFormer-Base* model: (a) referentna oznaka: deblo (crveno), grane (plavo), potpora (zeleno), (b) predikcija modela u istoj shemi boja, (c) prikaz uspješnosti na razini piksela za klasu grana: TP (zeleno), FP (crveno), FN (plavo).

Ova scena ilustrira tri systemske pogreške koje ostaju prisutne i u najboljem evaluiranom modelu. Prva i najizraženija pogreška vidljiva je u donjem panelu, gdje na lijevom rubu kadra ulazi drugo stablo. *DFormer-Base* model deblo tog drugog stabla ne prepoznaje dosljedno kao klasu debla, već ga uglavnom klasificira kao grane, što je na slici 5.5c vidljivo kao veliko crveno područje uz lijevi rub. Ova pogreška izravno potvrđuje ranije opažanje da model, čiji je skup za treniranje sadržavao gotovo isključivo scene s jednim stablom u kadru, ne generalizira dobro na kadrove s više stabala. Ovo je najjasniji kandidat za poboljšanje kroz predprocesiranje, primjerice izoliranje jednog stabla pomoću dubinske mape prije ulaska u segmentacijsku mrežu.

Druga pogreška odnosi se na klasu potpore. U referentnoj oznaci prikazanoj na slici 5.5a vidljive su horizontalne potporne žice u gornjem i donjem dijelu kadra te vertikalna potpora na

desnom rubu srednjeg panela. Predikcija modela prikazana na slici 5.5b ove regije u velikoj mjeri zanemaruje. Za razliku od globalne točnosti klase potpore od 96,46 % iz matrice zabune, u ovoj konkretnoj sceni potporne strukture pojavljuju se u konfiguracijama rijetko zastupljenim u skupu za treniranje, konkretno u izoliranoj horizontalnoj orijentaciji u perifernim regijama kadra bez susjednih vertikalnih stupova koji bi mrežu geometrijski usidrili.

Treća pogreška, blaža ali sistemska, vidljiva je u srednjem panelu u zoni prijelaza debela u primarne grane, gdje predikcija povremeno gubi kontinuitet debela. Ova pogreška izravno odgovara sistemskoj zabuni deblo/grane od 8,88 % iz matrice zabune na slici 5.4 i odražava zamućenu granicu između tih klasa u točkama grananja.

5.4.3. DFormer naspram ImageNet modela – mjerenje doprinosa prethodnog treniranja

Dosadašnje su usporedbe provedene unutar pojedine eksperimentalne faze. Kako bi se procijenio doprinos prethodnog treniranja baznog modela izravno na RGB-D podacima, u ovom se pododjeljku uspoređuju najbolji model prve eksperimentalne grupe, *ESANet* s baznim modelom *ResNet-34* prethodno treniranim na skupu *ImageNet* (Eksperiment 2), i najbolji model druge grupe, *DFormer-Base* (Eksperiment 4). Usporedba je smisljena jer su oba modela fino podešena i ocijenjena na istom skupu od 657 uzoraka i istom ispitnom skupu od 77 slika, a oba dubinsku informaciju obrađuju arhitekturno, a ne kao dodatni kanal na ulazu mreže, razlika među njima svodi se prvenstveno na to na kojim je podacima bazni model prethodno treniran. Pritom vrijedi ograničenje navedeno u potpoglavlju 4.9: dvije se grupe razlikuju i po optimizacijskom protokolu, pa izmjerena razlika predstavlja zajednički doprinos prethodnog treniranja i tog protokola. Vrijednosti svih uspoređivanih metrika prikazane su u tablici 5.12.

Tab. 5.12: Usporedba modela *DFormer-Base* (Eksperiment 4) i *ESANet* (najbolji model Eksperimenta 2) po pojedinim metrikama, vrijednosti u postocima.

Metrika	ESANet (Eks. 2)	DFormer-Base (Eks. 4)	Δ
mIoU	71,41	87,67	+16,26
mBF1	89,51	96,28	+6,77
Odziv grana	95,30	94,30	−1,00
IoU pozadina	99,06	98,61	−0,45
IoU deblo	81,25	81,69	+0,44
IoU grane	90,31	88,45	−1,86
IoU potpora	42,66	92,88	+50,22
BF1 pozadina	99,67	99,69	+0,02
BF1 deblo	81,99	93,65	+11,66
BF1 grane	96,28	98,12	+1,84
BF1 potpora	90,25	97,07	+6,82

Skok od +16,26 mIoU bodova predstavlja najznačajniju razliku uočenu kroz cijeli eksperimentalni okvir ovog rada, i po veličini nadmašuje sve razlike opažene između pojedinačnih *ImageNet* modela u Eksperimentima 1 do 3.

Raspodjela po klasama otkriva da je taj skok gotovo u potpunosti objašnjen velikim poboljšanjem klase potpore: +50,22 boda (42,66 % → 92,88 %). Klasa koja je bila najproblematičnija u svakom prethodnom eksperimentu postaje najbolje riješena klasa u *DFormer*-u. Preostale klase pokazuju znatno manje pomake: klasa debla +0,44 boda (praktički nepostojeća razlika), klasa pozadine −0,45 boda (marginalno), i klasa grana −1,86 boda. Ova posljednja stavka zaslužuje dodatnu pažnju. Iako je *DFormer-Base* blago lošiji od *ESANet*-a po IoU mjeri za klasu grana, po BF1 mjeri je istovremeno bolji (+1,84 boda). To znači da *DFormer* segmentira manje piksela klase grana, ali one koje segmentira ima geometrijski preciznije granice. Za praktičnu primjenu robotske rezidbe, gdje se rezovi izvode točno na spoju grane s deblom, preciznost granice važnija je od nešto veće pokrivenosti pikselima. Uvid iz BF1 metrike dodatno potvrđuje interpretaciju: uz spomenutu dobit od +50,22 IoU boda za klasu potpore, ista klasa istovremeno dobiva +6,82 BF1 boda, a klasa debla, unatoč gotovo identičnom IoU, dobiva izrazitih +11,66 BF1 bodova. Drugim riječima, prethodno treniranje baznog modela na RGB-D podacima ne samo da ispravno klasificira više piksela klase potpore, nego istovremeno daje oštrije granice i za klasu debla i za klasu potpore. Kombinacija ova dva pomaka izravno je relevantna za konačni cilj: precizan trodimenzionalni model stabla kao osnovu za daljnje planiranje putanje reznog manipulatora.

Model prethodno treniran na RGB-D podacima ne poboljšava sve klase ravnomjerno. On specifično i izrazito rješava upravo onaj problem koji je identificiran kroz potpoglavlje 2.4 i empirijski potvrđen kao fundamentalni nedostatak *post-hoc* adaptiranih RGB modela: razlikovanje geometrijski sličnih, ali semantički različitih tankih linearnih struktura (grane naspram potpornih žica).

5.5. Sveobuhvatna usporedba i diskusija

Tablica 5.13 sažima progresiju najboljih modela kroz sve četiri eksperimentalne faze i omogućuje izravnu usporedbu doprinosa pojedinih intervencija ispitivanih u ovom radu. Prijelaz iz Eksperi-

Tab. 5.13: *Usporedba najboljeg modela iz svake eksperimentalne faze.*

Faza	Najbolji model	mIoU (%)	mBF1 (%)	Odziv grana (%)	IoU potpora (%)
Eks. 1 – ImageNet, 399, jednokanalna dubina	U-Net EfficientNet-B4	57,22	84,48	93,33	20,58
Eks. 2 – ImageNet, 657, jednokanalna dubina	ESANet ResNet-34	71,41	89,51	95,30	42,66
Eks. 3 – ImageNet, 657, HHA enkodiranje dubine	U-Net EfficientNet-B4	68,32	82,02	93,27	41,17
Eks. 4 – RGB-D prethodno treniranje, 657	DFormer-Base	87,67	96,28	94,30	92,88

menta 1 u Eksperiment 2 (proširenje skupa s 399 na 657 uzoraka uz nepromijenjenu paradigmu prethodnog treniranja i jednokanalnu dubinu) donosi +14,19 mIoU boda i +5,03 mBF1 boda. Prijelaz iz Eksperimenta 2 u Eksperiment 3 (zamjena jednokanalne dubine s HHA enkodiranjem, uz isti skup podataka) rezultira degradacijom od −3,09 mIoU boda, izravno pobijajući očekivanje iz literature da HHA jednoznačno pomaže na svakoj domeni. Konačno, prijelaz iz Eksperimenta 2 u Eksperiment 4 (identičan skup podataka, ali se bazni model prethodno trenira na RGB-D podacima umjesto na skupu *ImageNet*) donosi +16,26 mIoU boda, što je najveći pojedinačni skok zabilježen kroz cijeli eksperimentalni okvir.

Osobito je informativan stupac IoU potpore: kreće od 20,58 % u Eksperimentu 1 (klasa gotovo neriješena), prelazi na 42,66 % u Eksperimentu 2 (djelomično riješena), stagnira na 41,17 % u Eksperimentu 3 (HHA ne pomaže), i skače na 92,88 % u Eksperimentu 4 (klasa gotovo u potpunosti riješena). Time raspon te metrike prelazi 72 postotna boda, što je daleko najveći raspon od svih četiriju klasa, što spomenuti stupac čini vrijednim dijagnostičkim pokazateljem koliko duboko model razumije trodimenzionalnu geometriju scene, te konkretnije koliko uspješno razlikuje tanke potporne žice od tankih grana, problem prepoznat u poglavlju 2 kao temeljno ograničenje RGB orijentiranih pristupa u ovoj domeni.

Iz cjeline izmjerenih rezultata proizlazi jasna hijerarhija važnosti triju istraživanih čimbenika. Paradigma prethodnog treniranja ima daleko najveći učinak, s +16,26 mIoU boda pri prijelazu s prethodnog treniranja na skupu *ImageNet* na prethodno treniranje na RGB-D podacima; proširenje podatkovnog skupa donosi u prosjeku +13,57 mIoU boda, dok promjena kodiranja dubinskog kanala ima blago negativan učinak od -1,97 mIoU boda. Za ovu domenu stoga vrijedi poredak: paradigma prethodnog treniranja > količina podataka > kodiranje dubinskog kanala.

Rezultat vezan uz HHA-kodiranje zaslužuje posebnu pozornost jer predstavlja negativan nalaz s vrijednim znanstvenim doprinosom. Prednost HHA-kodiranja poznata iz literature [5] ne prenosi se automatski na skup *BRANCHv2*, štoviše dovodi do blage ali dosljedne degradacije. Taj nalaz upozorava da za svaku novu kombinaciju skupa podataka i lanca obrade treba empirijski provjeriti kodiranje dubine s obzirom na to da uspješnost HHA-a u izvornome radu ovisi o dostupnosti stabilne referentne ravnine tla u kadru, što u agrarnim scenama snimanim iz blizine nije zajamčeno. Sličnu opreznost potvrđuje i unutarnja usporedba obitelji *DFormer*: *DFormer v2*, unatoč dokazanim poboljšanjima na standardnim referentnim skupovima, dosljedno zaostaje za *DFormerom v1* na ovoj domeni. Iz oba nalaza slijedi da vrhunska izvedba na općim referentnim skupovima ne povlači vrhunsku izvedbu na specijaliziranim domenama.

Segmentacija klase grana pokazuje se, s druge strane, kao razmjerno lako rješiv problem koji postiže prihvatljivu razinu već u ranijim eksperimentima. IoU klase grana postojan je kroz sve eksperimente (78–90 %) uz dosljedno visok odziv (87–95 %). Čak i razmjerno jednostavni modeli iz Eksperimenta 2, poput *ESANet*-a s 90,31 % IoU-a i 95,30 % odziva grana, postižu praktički korisnu razinu; dodatna složenost kakvu donosi *DFormer* prvenstveno pomaže u razlikovanju grana od potpore te u kvaliteti granica (BF1), a ne u osnovnoj detekciji grana. U istome svjetlu treba tumačiti i skaliranje unutar obitelji *DFormer*, gdje su razlike među varijantama *Small*, *Base* i *Large* male (unutar v1 manje od 0,5 boda), što upućuje na to da je 657 uzoraka blizu zasićenja korisnosti dodatnih parametara te da bi za daljnje poboljšanje rezultata dodatni podaci vjerojatno imali veći učinak od prelaska na veće varijante.

Na temelju svih iznesenih rezultata, *DFormer-Base* se istaknuo kao najbolji model za daljnji razvoj sustava autonomne rezidbe. Postiže najviši mIoU (87,67 %) i drugi najviši mBF1 (*DFormer-Base* i *DFormer-Large* praktički su izjednačeni po mBF1 (96,28 i 96,29)) od svih dvadeset i šest evaluiranih konfiguracija, uz izrazito poboljšanu detekciju potpore (92,88 %), koja je bila kritičan nedostatak svih ranijih pristupa. Brzina *inferencije* od 49,73 FPS čini ga i praktično primjenjivim za robotsku rezidbu koja ne zahtijeva obradu u stvarnome vremenu. Ipak, visoka agregatna metrika

ne jamči otpornost na svim rubnim slučajevima: modeli *DFormer* pokazuju sustavnu pogrešku u scenama s dvama stablima u kadru, gdje gotovo dosljedno segmentiraju drugo deblo kao klasu grana. Vrlo vjerojatno poboljšanje rezultata dalo bi uvođenje koraka predobrade koji bi iz ulazne slike izdvojio jedno stablo, primjerice postupkom detekcije zasnovanim na dubinskoj karti, te tako izdvojen kadar prosljedio *DFormer*-u kao ulaz. Time bi model uvijek primao sliku s jednim stablom, što odgovara raspodjeli podataka na kojoj je treniran, pa se može očekivati da bi sve evaluacijske metrike bile više od izmjerenih na sadašnjem ispitnom skupu koji sadrži i scene s više stabala.

5.5.1. Ograničenja tumačenja

Pri tumačenju iznesenih rezultata valja imati na umu nekoliko ograničenja koja proizlaze iz opsega skupa podataka i iz eksperimentalnoga ustroja. Cjelokupni skup podataka korišten u ovome radu obuhvaća 58 različitih stabala fotografiranih iz više gledišta, što ukupno daje 657 slika, dok ispitni skup sadrži svega 77 slika. Zbog toga su metrike po klasama, osobito IoU potpore koji ovisi o razmjerno malenu broju piksela potpore, podložne većoj statističkoj varijanci procjene nego agregatni mIoU. Uz to, sve iznesene metrike proizvod su jednog pokretanja svake konfiguracije, bez izračuna varijance kroz više inicijalizacija. S obzirom na to da se u literaturi tipične vrijednosti varijance za semantičku segmentaciju kreću u rasponu od 0,5 do 1,5 mIoU boda, razlike ispod toga reda veličine, primjerice razlike unutar obitelji *DFormer* manje od 0,5 boda, treba tumačiti oprezno, kao potencijalno unutar granica šuma inicijalizacije.

Dodatna se ograničenja odnose na provedbu i ocjenu *ESANet*-a. Ovdje prikazana provedba preuzima arhitektonsku zamisao usporednih grana enkodera i *SE*-modula za spajanje iz izvornoga rada [20], no koristi bazni model prethodno treniran nad *ImageNet* podacima, umjesto izvorno predloženog RGB-D specifično prethodnog treniranja, pa ova usporedba mjeri doprinos arhitekturnog rješenja (usporedne grane nasuprot ranomu spajanju na ulazu), a ne doprinos prethodnog treniranja. Nadalje, *ESANet* nije ocijenjen na HHA-ulazu zbog arhitektonske neusklađenosti jednokanalne dubinske grane s trokanalnim HHA-tenzorom, pa se učinak HHA-kodiranja ne može izravno usporediti između arhitektura U-Net i *ESANet*.

6. ZAKLJUČAK

Ovaj diplomski rad istražio je problem semantičke segmentacije grana stabala iz RGB-D slika, s ciljem razvoja pouzdane percepcijske komponente za sustave autonomne robotske rezidbe voćnjaka. Polazeći od nedostatka sustavne usporedbe strategija integracije dubinskog modaliteta i paradigmi prethodnog treniranja baznog modela, uočenog u literaturi na domeni obilježenoj tankim i geometrijski sličnim strukturama, definiran je eksperimentalni protokol podijeljen u četiri komplementarne faze. Sve su faze provedene na podatkovnom skupu *BRANCH v2* i evaluirane na zasebnom testnom skupu, odvojenom od skupova za učenje i validaciju, čime je osigurana objektivnost dobivenih rezultata.

Rezultati su otkrili jasnu hijerarhijsku važnost istraženih faktora. Paradigma prethodnog treniranja baznog modela pokazala se najutjecajnijim faktorom: prelazak s arhitektura prethodno treniranih na skupu *ImageNet* na one prethodno trenirane na RGB-D podacima, odnosno *DFormer* modele, s preporučenim optimizacijskim protokolima, donio je poboljšanje od +16,26 mIoU bodova, uz velik skok performansi u ovom eksperimentalnom okviru na klasi potpornih elemenata (s 42,66 % na 92,88 % IoU). Udio pojedinih komponenti u tom pomaku nije razlučen; procjena iz izvornih radova sugerira da 1–2 boda otpada na višerazmjerno testiranje, dok ostatak ostaje zajednički doprinos prethodnog treniranja i protokola treniranja. Količina podataka za fino podešavanje pokazala se kao drugi najvažniji faktor, s konzistentnim poboljšanjem od prosječno +13,57 mIoU bodova prilikom proširenja skupa s 399 na 657 uzoraka, dok je enkodiranje dubinskog kanala (HHA naspram jednokanalne dubine) imalo zanemariv, štoviše blago negativan učinak. Na temelju sveobuhvatne usporedbe svih 26 evaluiranih konfiguracija, *DFormer-Base* izdvojen je kao preporučeni model za daljnji razvoj sustava, budući da ostvaruje najvišu vrijednost mIoU (87,67 %) i drugu najvišu vrijednost mBF1 (96,28 %), uz manji računalni otisak od varijante *Large*, praktički identičnu izvedbu i prihvatljivu brzinu *inferencije* od 49,73 FPS koja zadovoljava zahtjeve robotske rezidbe. Ovi zaključci vrijede uz nekoliko važnih ograničenja: sve konfiguracije evaluirane su jednim pokretanjem, testni skup od 77 slika ograničen je na jedan tip agrarne sredine (voćnjak krušaka, snimke iz zimskog razdoblja), a implementacija *ESANet* arhitekture koristi *ImageNet* inicijalizaciju umjesto originalno predviđenog baznog modela prethodno treniranog na RGB-D podacima. Isto tako rezultati vrijede za već predobrađene snimke s uklonjenim tlom; primjena na sirovim snimkama iz voćnjaka zahtijevala bi izvođenje koraka uklanjanja tla u realnom vremenu, čija cijena i pouzdanost u ovom radu nisu mjerene.

Unatoč postignutim rezultatima, rad ukazuje na nekoliko konkretnih smjerova u kojima bi se razvijeni sustav mogao dodatno unaprijediti. Prvi i empirijski najbolje potkrijepljen smjer odnosi se na daljnje proširenje podatkovnog skupa. Rezultati Eksperimenta 2 jednoznačno su pokazali da je veličina skupa za fino podešavanje faktor s najvećim povratom uloženog rada jer svaki model, bez iznimke, ostvario je dvoznamenkasto poboljšanje mIoU isključivo zbog dodatnih 258 uzoraka, bez ikakve promjene arhitekture. Nastavak prikupljanja i anotacije podataka, pogotovo scena s rjeđim, ali kritičnim konfiguracijama (primjerice potporne žice u izravnoj blizini grana), predstavlja najizravniji i najpouzdaniji put prema daljnjem poboljšanju performansi. Drugi smjer odnosi se

na unaprjeđenje opreme korištene za snimanje podatkovnog skupa. Kvaliteta i preciznost dubinskog senzora izravno se prenosi na kvalitetu oblaka točaka iz kojeg se generiraju RGB-D parovi, a time i na sve daljnje korake obrade. Korištenje senzora s većom dubinskom rezolucijom i točnošću na radnoj udaljenosti karakterističnoj za rezidbu, te senzora robusnijih na vanjske uvjete osvjjetljenja, moglo bi smanjiti šum u dubinskom modalitetu već na samom izvoru. Treći smjer odnosi se na poboljšanje balansa klasa u podatkovnom skupu. Kroz sva četiri eksperimenta, klasa potpornih elemenata dosljedno je bila statistički najslabije zastupljena i istovremeno najteža za segmentaciju. Ciljano prikupljanje dodatnih uzoraka s povećanom zastupljenošću potpornih elemenata, eventualno u kombinaciji s tehnikama poput ponderiranog gubitka ili preuzrokovanja (engl. *oversampling-a*) rijetkih klasa vjerojatno bi dodatno povećalo robusnost detekcije ove sigurnosno osjetljive klase.

Osim navedenih triju smjerova, iz nalaza i ograničenja ovog rada proizlaze i dodatni pravci za buduća istraživanja. S metodološke strane, korisno bi bilo ponoviti eksperimente uz više nezavisnih treniranja po konfiguraciji, čime bi se razlike manje od približno jednog mIoU boda mogle pouzdanije razlikovati od varijance treniranja. Ostaje otvoreno i pitanje interakcijskih učinaka, primjerice bi li arhitektura prethodno trenirana na RGB-D podacima profitirala od HHA enkodiranja na način koji *ESANet*-u nije bio dostupan zbog arhitekturne nekompatibilnosti, ili bi razvoj domenski prilagođenog HHA *pipeline*-a mogao preokrenuti negativan rezultat iz Eksperimenta 3.

S praktične strane, istraživanje temporalne konzistencije predikcija kroz uzastopne okvire moglo bi pomoći u razlučivanju geometrijski dvosmislenih slučajeva. Zbog sigurnosne osjetljivosti zadatka, vrijedno bi bilo i istražiti metode procjene nesigurnosti predikcije. One bi sustavu omogućile da u graničnim slučajevima signalizira nisku pouzdanost i prepusti odluku operateru. Konačno, prije integracije u kompletan sustav za planiranje putanje robotskog rezača, potrebno bi bilo izmjeriti brzinu *inferencije* na ugrađenim platformama kakve se koriste u stvarnoj robotskoj primjeni.

Sveukupno, ovaj rad doprinosi razumijevanju relativne važnosti triju neovisnih čimbenika u RGB-D semantičkoj segmentaciji grana stabala, pruža vrijedne negativne rezultate koji upozoravaju na opasnost nekritičkog prenošenja nalaza iz opće literature na specijalizirane domene, te postavlja konkretne i empirijski utemeljene smjernice za nastavak razvoja sustava prema njegovoj eventualnoj primjeni u stvarnim uvjetima autonomne robotske rezidbe.

LITERATURA

- [1] A. Navone, M. Martini, M. Chiaberge, Autonomous robotic pruning in orchards and vineyards: A review, *Smart Agricultural Technology*, sv. 12, str. (101283), prosinac 2025.
- [2] S. A. Taghanaki i sur., Deep semantic segmentation of natural and medical images: a review, *Artificial Intelligence Review*, sv. 54, br. 1, str. (137–178), siječanj 2021.
- [3] J. Long, E. Shelhamer, T. Darrell, Fully Convolutional Networks for Semantic Segmentation, *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, str. (3431–3440), Boston, 2015.
- [4] O. Ronneberger, P. Fischer, T. Brox, U-Net: Convolutional Networks for Biomedical Image Segmentation, *Proceedings of the International Conference on Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, str. (234–241), München, 2015.
- [5] S. T. Digumarti i sur., An Approach for Semantic Segmentation of Tree-like Vegetation, *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*, str. (1801–1807), Montréal, 2019.
- [6] N. Silberman, D. Hoiem, P. Kohli, R. Fergus, Indoor Segmentation and Support Inference from RGBD Images, *Proceedings of the European Conference on Computer Vision (ECCV)*, str. (746–760), Firenca, 2012.
- [7] S. Song, J. Xiao, Deep Sliding Shapes for Amodal 3D Object Detection in RGB-D Images, *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, str. (808–816), Las Vegas, 2016.
- [8] J. Zhang i sur., CMX: Cross-Modal Fusion for RGB-X Semantic Segmentation with Transformers, *IEEE Transactions on Intelligent Transportation Systems*, sv. 24, br. 12, str. (14679–14694), prosinac 2023.
- [9] B. Yin, X. Zhang, Z. Li, L. Liu, M.-M. Cheng, Q. Hou, DFormer: Rethinking RGBD Representation Learning for Semantic Segmentation, *Proceedings of the International Conference on Learning Representations (ICLR)*, Beč, 2024.
- [10] B.-W. Yin, J.-L. Cao, M.-M. Cheng, Q. Hou, DFormerv2: Geometry Self-Attention for RGBD Semantic Segmentation, *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, str. (19345–19355), Nashville, 2025.
- [11] J. Dukić, P. Pejić, I. Vidović, E. K. Nyarko, Towards Robotic Pruning: Automated Annotation and Prediction of Branches for Pruning on Trees Reconstructed Using RGB-D Images, *Sensors*, sv. 25, br. 18, str. (5648), rujan 2025.

- [12] W. Ji, Z. Qian, B. Xu, Y. Tao, D. Zhao, S. Ding, Apple Tree Branch Segmentation from Images with Small Gray-Level Difference for Agricultural Harvesting Robot, *Optik*, sv. 127, br. 23, str. (11173–11182), prosinac 2016.
- [13] Z. Chen, K. Granland, R. Newbury, C. Chen, HOB-CNN: Hallucination of occluded branches with a convolutional neural network for 2D fruit trees, *Smart Agricultural Technology*, sv. 3, str. (100096), veljača 2023.
- [14] H. Sun, G. Wu, H. Xu, J. Li, Z. Zhou, S. Tao, W. Guo, K. Qi, H. Yin, S. Zhang, S. Ninomiya, Y. Mu, Real-time detection and characterization of trunks and upright branches of pear trees for automatic dormant pruning, *Precision Agriculture*, sv. 27, br. 2, str. (23), veljača 2026.
- [15] E. Kok, X. Wang, C. Chen, Obscured Tree Branches Segmentation and 3D Reconstruction Using Deep Learning and Geometrical Constraints, *Computers and Electronics in Agriculture*, sv. 210, str. (107884), srpanj 2023.
- [16] H. Sarbolandi, D. Lefloch, A. Kolb, Kinect range sensing: Structured-light versus Time-of-Flight Kinect, *Computer Vision and Image Understanding*, sv. 139, str. (1–20), listopad 2015.
- [17] L. Keselman, J. I. Woodfill, A. Grunnet-Jepsen, A. Bhowmik, Intel RealSense Stereoscopic Depth Cameras, *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, str. (1267–1276), Honolulu, 2017.
- [18] M. Camplani, L. Salgado, Efficient spatio-temporal hole filling strategy for Kinect depth maps, *Three-Dimensional Image Processing (3DIP) and Applications II*, volume 8290, str. (82900E), Burlingame, 2012.
- [19] S. Gupta, R. Girshick, P. Arbeláez, J. Malik, Learning Rich Features from RGB-D Images for Object Detection and Segmentation, *Proceedings of the European Conference on Computer Vision (ECCV)*, str. (345–360), Zürich, 2014.
- [20] D. Seichter, M. Köhler, B. Lewandowski, T. Wengelfeld, H.-M. Gross, Efficient RGB-D Semantic Segmentation for Indoor Scene Analysis, *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*, str. (13525–13531), Xi'an, 2021.
- [21] P. Raunonen i sur., Fast Automatic Precision Tree Models from Terrestrial Laser Scanner Data, *Remote Sensing*, sv. 5, br. 2, str. (491–520), siječanj 2013.
- [22] S. T. Digumarti i sur., Automatic Segmentation of Tree Structure from Point Cloud Data, *IEEE Robotics and Automation Letters*, sv. 3, br. 4, str. (3043–3050), listopad 2018.
- [23] Y. Majeed, J. Zhang, X. Zhang, L. Fu, M. Karkee, Q. Zhang, M. D. Whiting, Apple Tree Trunk and Branch Segmentation for Automatic Trellis Training Using Convolutional Neural Network Based Semantic Segmentation, *IFAC-PapersOnLine*, sv. 51, br. 17, str. (75–80), 2018.

- [24] C. R. Qi, H. Su, K. Mo, L. J. Guibas, PointNet: Deep Learning on Point Sets for 3D Classification and Segmentation, Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), str. (652–660), Honolulu, 2017.
- [25] C. R. Qi, L. Yi, H. Su, L. J. Guibas, PointNet++: Deep Hierarchical Feature Learning on Point Sets in a Metric Space, Advances in Neural Information Processing Systems (NeurIPS), str. (5099–5108), Long Beach, 2017.
- [26] K. He, X. Zhang, S. Ren, J. Sun, Deep Residual Learning for Image Recognition, Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), str. (770–778), Las Vegas, 2016.
- [27] J. Yosinski, J. Clune, Y. Bengio, H. Lipson, How Transferable Are Features in Deep Neural Networks?, Advances in Neural Information Processing Systems (NeurIPS), str. (3320–3328), Montréal, 2014.
- [28] L.-C. Chen, Y. Zhu, G. Papandreou, F. Schroff, H. Adam, Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation, Proceedings of the European Conference on Computer Vision (ECCV), str. (801–818), München, 2018.
- [29] A. Vaswani i sur., Attention Is All You Need, Advances in Neural Information Processing Systems (NeurIPS), str. (5998–6008), Long Beach, 2017.
- [30] E. Xie, W. Wang, Z. Yu, A. Anandkumar, J. M. Alvarez, P. Luo, SegFormer: Simple and Efficient Design for Semantic Segmentation with Transformers, Advances in Neural Information Processing Systems (NeurIPS), str. (12077–12090), virtualna konferencija, 2021.
- [31] B. Cheng i sur., Masked-attention Mask Transformer for Universal Image Segmentation, Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), str. (1290–1299), New Orleans, 2022.
- [32] P. Isola, J.-Y. Zhu, T. Zhou, A. A. Efros, Image-to-Image Translation with Conditional Adversarial Networks, Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), str. (1125–1134), Honolulu, 2017.
- [33] J. Dukić, P. Pejić, A. Bošnjak, E. K. Nyarko, BRANCH – a Labeled Dataset of RGB-D Images and 3D Models for Autonomous Tree Pruning, Proceedings of the 2024 International Conference on Smart Systems and Technologies (SST), str. (57–64), Osijek, 2024.
- [34] J. Dukić, P. Pejić, I. Vidović, E. K. Nyarko, BRANCH.v2 dataset [online], Sveučilište Josipa Jurja Strossmayera u Osijeku, FERIT, Osijek, 2025, dostupno na: <https://puh.srce.hr/s/EoPqgASGerLapne> [29.8.2026.].

SAŽETAK

Zadatak ovog diplomskog rada bio je implementacija i dodatno treniranje postojećih dubokih neuronskih mreža za semantičku segmentaciju i detekciju grana stabala primjenom fuzije podataka o boji (RGB) i dubini (D), s ključnim ciljem preciznog razlikovanja grana od debla te pouzdane klasifikacije ostalih objekata u sceni, poput potpornih stupova i žica, koji se geometrijski mogu zamijeniti s granama. Za sustavno rješavanje ovog zadatka provedena je eksperimentalna analiza utjecaja triju čimbenika na kvalitetu segmentacije: veličine podatkovnog skupa za fino podešavanje, strategije enkodiranja modaliteta dubine na ulazu mreže te paradigme prethodnog treniranja baznog modela (skup *ImageNet* naspram RGB-D podataka). Eksperimenti su provedeni kroz četiri faze na podatkovnom skupu *BRANCH v2*, obuhvaćajući niz konvolucijskih, generativnih i transformer-skih arhitektura, uz evaluaciju standardiziranim skupom metrika radi izravne usporedivosti rezultata. Rezultati pokazuju da proširenje skupa s 399 na 657 uzoraka donosi prosječno poboljšanje od +13,57 mIoU bodova, dok HHA enkodiranje dubine, suprotno očekivanjima iz literature, blago degradira performanse (−1,97 mIoU). Najveći učinak ima prethodno treniranje na RGB-D podacima: model *DFormer-Base* ostvaruje mIoU od 87,67 % i mBF1 od 96,28 %, uz poboljšanu klasifikaciju potpornih stupova i žica (s 42,66 % na 92,88 % IoU) u odnosu na najbolji model prethodno treniran na skupu *ImageNet*. Postignuti rezultati uspostavljaju empirijsku hijerarhiju važnosti istraženih čimbenika i daju konkretne smjernice za daljnji razvoj sustava autonomne robotske rezidbe.

Ključne riječi: duboko učenje, grane stabala, RGB-D slike, robotska rezidba, semantička segmentacija

ABSTRACT

Semantic segmentation of tree branches from RGB-D images using deep learning

The task of this thesis was to implement and further train existing deep neural networks for the semantic segmentation and detection of tree branches using a fusion of color (RGB) and depth (D) data, with the key goal of precisely distinguishing branches from the trunk and reliably classifying other objects in the scene, such as support poles and wires, which can be geometrically mistaken for branches. To systematically address this task, an experimental analysis was conducted of the impact of three design decisions on segmentation quality: the size of the fine-tuning dataset, the strategy for encoding the depth modality at the network input, and the backbone pretraining paradigm (ImageNet versus RGB-D-specific pretraining). The experiments were conducted in four phases on the BRANCH v2 dataset, covering a range of convolutional, generative, and transformer-based architectures, all evaluated using a standardised set of evaluation metrics to ensure direct comparability of results. The results show that expanding the dataset from 399 to 657 samples yields an average improvement of +13.57 mIoU points, whereas HHA depth encoding, contrary to expectations from the literature, slightly degrades performance (-1.97 mIoU). The largest effect stems from RGB-D-specific pretraining: the DFormer-Base model achieves an mIoU of 87.67% and an mBF1 of 96.28%, with improvement in the classification of support poles and wires (from 42.66% to 92.88% IoU) compared to the best ImageNet-pretrained model. The results establish an empirical hierarchy of the importance of the investigated factors and provide concrete guidelines for the further development of autonomous orchard-pruning robotic systems.

Keywords: deep learning, RGB-D images, robotic pruning, semantic segmentation, tree branches

ŽIVOTOPIS

Samuel Adžić rođen je 17. kolovoza 2002. godine u Osijeku. Osnovno obrazovanje završio je u Osnovnoj školi Matije Petra Katančića u Valpovu. Nakon završetka osnovne škole upisao je opću gimnaziju u Srednjoj školi Valpovo, koju je uspješno završio polaganjem državne mature. Godine 2021. upisao je preddiplomski sveučilišni studij Računarstvo na Fakultetu elektrotehnike, računarstva i informacijskih tehnologija Osijek (FERIT), smjer Programsko inženjerstvo. Studij je završio u predviđenom roku te stekao akademski naziv sveučilišni prvostupnik (baccalaureus) inženjer računarstva. Nakon završetka preddiplomskog studija upisao je diplomski sveučilišni studij Računarstvo na Fakultetu elektrotehnike, računarstva i informacijskih tehnologija Osijek, modul DRB – Robotika i umjetna inteligencija. Tijekom studija usmjerio je interes prema područjima umjetne inteligencije, robotike i industrijske automatizacije.

Potpis autora